

Variational Bayes-Hidden Markov Model Analysis for Time Series Data

Kenji Okamoto

March 24, 2016

Contents

1	General Solution	3
1.1	Solution of Variational Bayes	3
1.1.1	Basic principle	3
1.1.2	Mean field approximation	4
1.1.3	変分ベイズ法の EM アルゴリズム	5
1.1.4	下限値 $\mathcal{L}(q)$ の算出	5
1.1.5	モデル選択、混合要素数の決定	5
1.2	Hidden Markov Model の解法	6
1.2.1	状態を表す潜在変数の定義	6
1.2.2	一般式	6
1.2.3	EM アルゴリズムによる HMM 解法	7
1.3	Solution of Variational Bayes-Hidden Markov Model	10
1.3.1	E-step	10
1.3.2	M-step	11
1.3.3	変分下限 $\mathcal{L}(q)$ の算出	13
1.4	Global Hidden Markov Model の変分ベイズ解法	15
1.4.1	E-step	16
1.4.2	M-step	17
1.4.3	変分下限 $\mathcal{L}(q)$ の算出	20
2	Gaussian Time Series	22
2.1	汎用 Gauss 分布	22
2.1.1	Gaussian 信号	22
2.1.2	E-step :	23
2.1.3	M-step :	23
2.1.4	変分下限 $\mathcal{L}(q)$ の算出	27
2.1.5	global analysis 対応	29
2.2	Gaussian 1 分子蛍光強度信号	30
2.2.1	E-step :	30
2.2.2	M-step :	31
2.2.3	変分下限 $\mathcal{L}(q)$ の算出	34
2.3	2 次元ブラウン運動の動径分布	36
2.3.1	E-step :	37

2.3.2	M-step :	37
2.3.3	変分下限 $\mathcal{L}(q)$ の算出	38

Chapter 1

General Solution

1.1 Solution of Variational Bayes

1.1.1 Basic principle

最尤法では、得られた観測データ \mathbf{X} に対して尤度関数 $p(\mathbf{X}|\Theta)$ を最大化するパラメータセット Θ を求めることを目的とする。

変分ベイズ法では、尤度関数をパラメータで周辺化したエビデンス

$$p(\mathbf{X}) = \int d\Theta p(\Theta)p(\mathbf{X}|\Theta) \quad (1.1)$$

を取り扱う。

エビデンス $p(\mathbf{X})$ は次のように変形できる。

$$\ln p(\mathbf{X}) = \mathcal{L}(q) + \text{KL}(q||p) \quad (1.2)$$

ただし、

$$\mathcal{L}(q) = \sum_{\mathbf{z}} \int d\Theta q(\mathbf{Z}, \Theta) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}, \Theta)}{q(\mathbf{Z}, \Theta)} \right\} \quad (1.3)$$

$$\text{KL}(q||p) = - \sum_{\mathbf{z}} \int d\Theta q(\mathbf{Z}, \Theta) \ln \left\{ \frac{p(\mathbf{Z}, \Theta|\mathbf{X})}{q(\mathbf{Z}, \Theta)} \right\} \quad (1.4)$$

とする。ただし、 \mathbf{Z} は潜在変数、 Θ はパラメータ。 q は \mathbf{Z} および Θ の分布関数であり、 $\mathcal{L}(q)$, $\text{KL}(q||p)$ は q の汎関数 (関数を引数とする関数)。

潜在変数とパラメータに関して、真の分布関数 p に近似できる分布関数 q を求めたい。この時、

- Kullback-Leibler ダイバージェンス $\text{KL}(q||p)$ は、2つの分布関数 p, q の相似の程度を表す (小さいほど似通っている)。
- エビデンスの下限 $\mathcal{L}(q)$ 項と、 $\text{KL}(q||p)$ 項は、ともに非負。

- エビデンス $p(\mathbf{X})$ は既知の \mathbf{X} にのみ依存しており、(未知ではあるが) 1つの固定値を持っている。

といった点に注目すると、KL 項を最小化することと、 $\mathcal{L}(q)$ 項を最大化することが等価な目標であることが分かる。

変分ベイズ法では、エビデンスの下限值 (変分下限) $\mathcal{L}(q)$ を最大化する分布関数 q を求める。 $\mathcal{L}(q)$ の q での汎関数微分 (変分) に基づいて解くので、変分ベイズと呼ぶ。

1.1.2 Mean field approximation

実際に解くには、物理学における平均場近似に近い考え方をを用いる。

パラメータと潜在変数をまとめて \mathbf{Z} とした時、

$$q(\mathbf{Z}) = \prod_{i=1}^M q_i(\mathbf{Z}_i) \quad (1.5)$$

に分解できるとすると、

$$\mathcal{L}(q) = \int q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z}|K)}{q(\mathbf{Z})} \right\} d\mathbf{Z} \quad (1.6)$$

$$= \int \prod_i q_i \left\{ \ln p(\mathbf{X}, \mathbf{Z}|K) - \sum_i \ln q_i \right\} d\mathbf{Z} \quad (1.7)$$

$$= \int q_j \left\{ \int \ln p(\mathbf{X}, \mathbf{Z}|K) \prod_{i \neq j} q_i d\mathbf{Z}_i \right\} d\mathbf{Z}_j - \int q_i \ln q_i d\mathbf{Z}_i + \text{const.} \quad (1.8)$$

$$= \int q_j \ln \tilde{p}(\mathbf{X}, \mathbf{Z}_j|K) d\mathbf{Z}_j - \int q_j \ln q_j d\mathbf{Z}_j + \text{const.} \quad (1.9)$$

ただし、 $\mathbb{E}_{i \neq j}[\dots]$ は期待値を表すとして、

$$\tilde{p}(\mathbf{X}, \mathbf{Z}_j) = \mathbb{E}_{i \neq j}[\ln p(\mathbf{X}, \mathbf{Z}|K)] + \text{const.} \quad (1.10)$$

$\{q_{i \neq j}\}$ を固定化 (平均場近似) した上で $\mathcal{L}(q)$ が最大化するのは、式 (1.9) が負の KL-ダイバージェンスの関係であることに注意すると、 $q_i(\mathbf{Z}_j) \cong \tilde{p}(\mathbf{X}, \mathbf{Z}_j)$ の時なので、最適解 $q_j^*(\mathbf{Z}_j)$ は、

$$\ln q_j^*(\mathbf{Z}_j) = \mathbb{E}_{i \neq j}[\ln p(\mathbf{X}, \mathbf{Z}|K)] + \text{const.} \quad (1.11)$$

で与えられる。

1.1.3 変分ベイズ法の EM アルゴリズム

潜在変数 $\mathbf{Z} = \{z_1, z_2, \dots, z_N\}$ とパラメータ θ について

$$q(\mathbf{Z}, \theta) = q(\mathbf{Z})q(\theta) \quad (1.12)$$

に分離できるとすると、平均場近似によってそれぞれ、

$$\ln q^*(\mathbf{Z}) = \mathbb{E}_\theta[\ln p(\mathbf{X}, \mathbf{Z}, \theta|K)] + \text{const.} \quad (1.13)$$

を求める E-step と

$$\ln q^*(\theta) = \mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z}, \theta|K)] + \text{const.} \quad (1.14)$$

を求める M-step を繰り返せばよい。

1.1.4 下限値 $\mathcal{L}(q)$ の算出

式 (1.2) で表されるエビデンスの中で、最大値の下限を表す $\mathcal{L}(q)$ 項は、最適化ステップが進むとともに単調に増加する。そこでこの値をステップ毎に計算することで、計算が正しく行われていることの確認になる。

また、最適化が完了した時にはエビデンスの近似値となるので、収束の確認、モデル間の比較等をおこなうためにも $\mathcal{L}(q)$ の値を計算する必要がある。

$\mathcal{L}(q)$ はさらに、

$$\mathcal{L}(q) = \sum_{\mathbf{z}} \int d\theta q(\mathbf{Z}, \theta) \ln p(\mathbf{X}, \mathbf{Z}, \theta) - \sum_{\mathbf{z}} \int d\theta q(\mathbf{Z}, \theta) \cdot \ln q(\mathbf{Z}, \theta) \quad (1.15)$$

$$= \mathbb{E}_{\mathbf{Z}, \theta}[\ln p(\mathbf{X}, \mathbf{Z}, \theta)] - \mathbb{E}_{\mathbf{Z}, \theta}[\ln q(\mathbf{Z}, \theta)] \quad (1.16)$$

と展開でき、実際にはこれを計算する。

EM-アルゴリズムでは、E-step で \mathbf{Z} 分布を更新した直後に変分下限 $\mathcal{L}(q)$ を計算し、収束判定等をおこなう。

1.1.5 モデル選択、混合要素数の決定

変分ベイズ法は複数のモデル間での最適モデル選択に用いることもできる。モデル m に対して、規格化された変分下限 $\mathcal{L}(q|m)$ を求め、

$$p(m)\mathcal{L}(q|m) \quad (1.17)$$

を計算して比較すればよい。

$p(m)$ は各モデルについての事前分布であり、各 m について $p(m) = 1$ とすることができれば、直接 $\mathcal{L}(q|m)$ を比較すればよいことになる。

混合ガウス分布のように、等価な複数の分布の混合分布を考える場合、最適解から混合要素同士を入れ替えた別の設定もまた最適解となる。そのような等価なパラメータ設定の組み合わせは、 K 個の混合要素を考えた場合、 $K!$ 通りとなる。

ちなみに、最尤推定の場合には、この冗長性は問題にならない。最適解は、パラメータの初期値に依存して 1 つだけ求められ、それ以外の等価な解は無関係となる。

この影響を取り除くためには、最も簡単な近似は、得られた変分下限に $\ln K!$ を加えることである。

したがって、要素数の異なる混合分布の間でモデル選択する場合には、

$$p(K) \{ \mathcal{L}(q|K) + \ln K! \} \quad (1.18)$$

を各 K について求めて比較すればよい。

1.2 Hidden Markov Model の解法

1.2.1 状態を表す潜在変数の定義

全部で N 個あるデータ点 $\mathbf{X} = \{x_1, x_2, \dots, x_N\}$ それぞれが、 $1 \dots K$ 状態のいずれかに属するとする。

$N \times K$ ベクトルとして潜在変数 $\mathbf{Z} = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_N\}$, $\mathbf{z}_n = \{z_{n1}, z_{n2}, \dots, z_{nK}\}$ を定義する。各データ点がどの状態に属するかを表すため、

$$z_{nk} = \begin{cases} 0 \\ 1 \end{cases} \quad (1.19)$$

$$\sum_{i=1}^K z_{ni} = 1 \quad (1.20)$$

とする。つまり、各 n に対して 1 つだけが 1 となり、残りは 0 となる。

1.2.2 一般式

一般的な (たとえば混合 Gauss 分布) の HMM を解く場合には、 \mathbf{X}, \mathbf{Z} の同時分布を以下のように書き下す。

$$p(\mathbf{X}, \mathbf{Z} | \theta) = p(\mathbf{z}_1 | \theta) \times \prod_{n=2}^N p(\mathbf{z}_n | \mathbf{z}_{n-1}, \theta) \times \prod_{m=1}^N p(x_m | \mathbf{z}_m, \theta) \quad (1.21)$$

このうち、 $p(\mathbf{z}_1 | \theta)$ と $p(\mathbf{z}_n | \mathbf{z}_{n-1}, \theta)$ に関しては一般的に、

$$p(\mathbf{z}_1 | \boldsymbol{\pi}) = \prod_{i=1}^K \pi_i^{z_{1i}} \quad (1.22)$$

$$p(\mathbf{z}_n | \mathbf{z}_{n-1}, \mathbf{A}) = \prod_{i=1}^K \prod_{j=1}^K A_{ij}^{z_{n-1,i} z_{nj}} \quad (1.23)$$

とすることができる。ただし、 π_i は初期状態が i 状態である確率を表すパラメータで、 $\sum_{i=1}^K \pi_i = 1$ 。 A_{ij} は i 状態から次のステップで j 状態に遷移する確率 ($i = j$ の場合 i 状態に留まる確率) を表すパラメータ行列で、 $\sum_{j=1}^K A_{ij} = 1$ 。
 π, A 以外の、主に $p(x_m|z_m)$ に関わるパラメータを、まとめて ϕ で表す。

1.2.3 EM アルゴリズムによる HMM 解法

HMM を最尤法で解くためには、式 (1.21) 尤度関数を最大化するパラメータセット θ を求める必要がある。しかし、 Z が未知のため、このままでは解くことが出来ない。

そこで、仮に与えたパラメータ θ^{old} を基にして Z の期待値を求めることにして、式 (1.21) の対数尤度を書き直した

$$Q(\theta, \theta^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}}) \cdot \ln p(\mathbf{X}, \mathbf{Z}|\theta) \quad (1.24)$$

を求める。

ここで新たな変数 γ, ξ を導入する。

$$\gamma(\mathbf{z}_n) = p(\mathbf{z}_n|\mathbf{X}, \theta^{\text{old}}) \quad (1.25)$$

$$\gamma(z_{nk}) = \mathbb{E}[z_{nk}] = \sum_{\mathbf{z}_n} \gamma(\mathbf{z}_n) \cdot z_{nk} \quad (1.26)$$

$$\xi(\mathbf{z}_n, \mathbf{z}_{n-1}) = p(\mathbf{z}_{n-1}, \mathbf{z}_n|\mathbf{X}, \theta^{\text{old}}) \quad (1.27)$$

$$\xi(z_{n-1,i}, z_{nj}) = \mathbb{E}[z_{n-1,i} z_{nj}] = \sum_{\mathbf{z}_n, \mathbf{z}_{n-1}} \xi(\mathbf{z}_n, \mathbf{z}_{n-1}) \cdot z_{n-1,i} z_{nj} \quad (1.28)$$

$\gamma(z_{nk})$ は、 n 番目のデータ点が k 状態に属する確率、 $\xi(z_{n-1,i}, z_{nj})$ は $n-1$ から n の間に i 状態から j 状態に遷移する確率を表す。

これにより、

$$\begin{aligned} Q(\theta, \theta^{\text{old}}) = & \sum_{i=1}^K \gamma(z_{1i}) \ln \pi_i + \sum_{n=2}^N \sum_{i=1}^K \sum_{j=1}^K \xi(z_{n-1,i}, z_{nj}) \ln A_{ij} \\ & + \sum_{n=1}^N \sum_{i=1}^K \gamma(z_{ni}) \ln p(x_n|\theta) \end{aligned} \quad (1.29)$$

と書き直す。

EM アルゴリズムでは、仮の θ_{old} を基に γ, ξ 分布を求める E-step と、得られた γ, ξ 分布から θ の最尤値を更新する M-step とを、M-step で得られた θ を次の E-step の θ_{old} として与えることで、値が収束するまで反復計算する。

E-step

E-step では、 γ, ξ を求める。

Forward-backward (Baum-Welch) アルゴリズム :

γ は

$$\gamma(\mathbf{z}_n) = \frac{p(\mathbf{X}|\mathbf{z}_n) \cdot p(\mathbf{z}_n)}{p(\mathbf{X})} \quad (1.30)$$

$$= \frac{\alpha(\mathbf{z}_n) \cdot \beta(\mathbf{z}_n)}{p(\mathbf{X})} \quad (1.31)$$

と書くことができる。ただし、

$$\alpha(\mathbf{z}_n) \equiv p(x_1, \dots, x_n, \mathbf{z}_n) \quad (1.32)$$

$$\beta(\mathbf{z}_n) \equiv p(x_{n+1}, \dots, x_N | \mathbf{z}_n) \quad (1.33)$$

と定義する。ここで、スケーリング係数 c_n を導入する。

$$c_n = p(x_n | x_1, x_2, \dots, x_{n-1}) \quad (1.34)$$

とすると、乗法定理より

$$p(x_1, x_2, \dots, x_n) = \prod_{m=1}^n c_m \quad (1.35)$$

これを用いて α, β をそれぞれ

$$\hat{\alpha}(\mathbf{z}_n) = \frac{\alpha(\mathbf{z}_n)}{\prod_{m=1}^n c_m} = p(\mathbf{z}_n | x_1, x_2, \dots, x_n) \quad (1.36)$$

$$\hat{\beta}(\mathbf{z}_n) = \frac{\beta(\mathbf{z}_n)}{\prod_{m=n+1}^N c_m} = \frac{p(x_{n+1}, \dots, x_N | \mathbf{z}_n)}{\prod_{m=n+1}^N c_m} \quad (1.37)$$

$\hat{\alpha}$ に関しては、

$$\hat{\alpha}(\mathbf{z}_n) = \frac{p(x_n | \mathbf{z}_n)}{c_n} \sum_{\mathbf{z}_{n-1}} \hat{\alpha}(\mathbf{z}_{n-1}) \cdot p(\mathbf{z}_n | \mathbf{z}_{n-1}) \quad (1.38)$$

と再帰式に展開することができ、

$$\hat{\alpha}(\mathbf{z}_1) = \frac{p(x_1 | \mathbf{z}_1)}{p(x_1)} = \frac{p(x_1 | \mathbf{z}_1)}{\sum_{\mathbf{z}_1} p(x_1 | \mathbf{z}_1)} \quad (1.39)$$

を得ることができるので、全領域で $\hat{\alpha}$ が得られる。 β に関しても、

$$\hat{\beta}(\mathbf{z}_n) = \frac{1}{c_n} \sum_{\mathbf{z}_{n+1}} \hat{\beta}(\mathbf{z}_{n+1}) \cdot p(x_{n+1} | \mathbf{z}_{n+1}) \cdot p(\mathbf{z}_{n+1} | \mathbf{z}_n) \quad (1.40)$$

と再帰式に展開することができ、

$$\hat{\beta}(z_{Nk}) = 1 \quad (1.41)$$

とすればよいので、全領域で $\hat{\beta}$ が得られる。

$\hat{\alpha}, \hat{\beta}$ を用いると、式 (1.31) を書き直して、 γ に関して、

$$\gamma(\mathbf{z}_n) = \hat{\alpha}(\mathbf{z}_n) \cdot \hat{\beta}(\mathbf{z}_n) \quad (1.42)$$

ξ に関して

$$\xi(\mathbf{z}_{n-1}, \mathbf{z}_n) = \frac{1}{c_n} \hat{\alpha}(\mathbf{z}_{n-1}) \cdot p(x_n | \mathbf{z}_n) \cdot p(\mathbf{z}_n | \mathbf{z}_{n-1}) \cdot \hat{\beta}(\mathbf{z}_n) \quad (1.43)$$

により、全領域で得ることができる。

また、

$$p(\mathbf{X}) = \prod_{n=1}^N c_n \quad (1.44)$$

から尤度を得ることが出来る。

M-step

E-step で得られた γ, ξ を用いて、パラメータ値を更新する。

$$\pi_k = \frac{\gamma(z_{1i})}{\sum_{j=1}^K \gamma(z_{1j})} \quad (1.45)$$

$$A_{ij} = \frac{\sum_{n=2}^N \xi(z_{n-1,i}, z_{nj})}{\sum_{n=2}^N \sum_{k=1}^K \xi(z_{n-1,i}, z_{nk})} \quad (1.46)$$

ϕ に関しては、 $p(x_n | \mathbf{z}_n)$ の関数形に依存する。ラグランジュ乗数を用いるなどして更新式を求める。

Max-Sum (Viterbi) アルゴリズム

各 n について最大の $\gamma(z_{nk})$ を選ぶことが、最適な軌跡を復元することにはならない。 $\hat{\theta}$ を最尤パラメータとして、 $p(\mathbf{Z} | \mathbf{X}, \hat{\theta})$ を最大化する \mathbf{Z} を選ぶ必要がある。

そのために、次の再帰式を計算する。

$$\omega(\mathbf{z}_n) = \ln p(x_n|\mathbf{z}_n) + \max_{\mathbf{z}_{n-1}} \{ \ln p(\mathbf{z}_n|\mathbf{z}_{n-1}) + \omega(\mathbf{z}_{n-1}) \} \quad (1.47)$$

$$\omega(\mathbf{z}_1) = \ln p(\mathbf{z}_1) + \ln p(x_1|\mathbf{z}_1) \quad (1.48)$$

またその再帰計算の際、

$$\phi(z_{nj}^{\max}) = z_{n-1,i}^{\max} \quad (1.49)$$

を記録しておく。

最後に、 $n = N$ から ϕ を利用して順に遡りながら、 $p(\mathbf{Z}|\mathbf{X}, \hat{\theta})$ を最大化する経路を復元する。

1.3 Solution of Variational Bayes-Hidden Markov Model

1.3.1 E-step

最尤法の場合と同様に、forward-backward アルゴリズムにより、 γ, ξ 分布を得ることが目的。

一般的な HMM で用いられる forward-backward アルゴリズムとは、要するに、 \mathbf{Z} 分布を規定する同時分布 $p(\mathbf{X}, \mathbf{Z}|\theta)$ から γ, ξ 分布を得る計算法である。

変分ベイズでは、 \mathbf{Z} 分布は $q(\mathbf{Z})$ 関数によって与えられるので、(平均場近似のためパラメータで期待値をとった後の) $q(\mathbf{Z})$ 関数に対して forward-backward アルゴリズムを適用する。

$q^*(\mathbf{Z})$ を計算すると、

$$\begin{aligned} \ln q^*(\mathbf{Z}) = & \mathbb{E}_\pi \left[\sum_i^K z_{1i} \ln \pi_i \right] + \mathbb{E}_A \left[\sum_{n=2}^N \sum_i^K \sum_j^K z_{n-1,i} z_{nj} \ln A_{ij} \right] \\ & + \mathbb{E}_\theta \left[\sum_{m=1}^N \ln p(x_m|\mathbf{z}_m, \theta, K) \right] + \text{const.} \end{aligned} \quad (1.50)$$

$$\begin{aligned} = & \sum_i^K z_{1i} \overline{\ln \pi_i} + \sum_{n=2}^N \sum_i^K \sum_j^K z_{n-1,i} z_{nj} \overline{\ln A_{ij}} \\ & + \sum_{m=1}^N \overline{\ln p(x_m|\mathbf{z}_m, \theta, K)} + \text{const.} \end{aligned} \quad (1.51)$$

したがって、

$$q^*(\mathbf{Z}) \propto \prod_i^K \exp(\overline{\ln \pi_i})^{z_{1i}} \times \prod_{n=2}^N \prod_i^K \prod_j^K \exp(\overline{\ln A_{ij}})^{z_{n-1,i} z_{nj}} \\ \times \prod_{m=1}^N \exp(\overline{\ln p(x_m | \mathbf{z}_m, \theta, K)}) \quad (1.52)$$

となる。そこで、

$$\tilde{p}(\mathbf{z}_1 | \theta, K) = \prod_i^K \exp(\overline{\ln \pi_i})^{z_{1i}} \quad (1.53)$$

$$\tilde{p}(\mathbf{z}_n | \mathbf{z}_{n-1}, \theta, K) = \prod_i^K \prod_j^K \exp(\overline{\ln A_{ij}})^{z_{n-1,i} z_{nj}} \quad (1.54)$$

$$\tilde{p}(x_m | \mathbf{z}_m, \theta, K) = \exp(\overline{\ln p(x_m | \mathbf{z}_m, \theta, K)}) \quad (1.55)$$

をそれぞれ $p(\mathbf{z}_1, \theta, K)$, $p(\mathbf{z}_n | \mathbf{z}_{n-1}, \theta, K)$, $p(x_m | \mathbf{z}_m, \theta, K)$ の代わりに用いて forward-backward アルゴリズムを実行し、 γ, ξ 分布を得る。

各パラメータには期待値 ($\overline{\ln \pi_i}$, $\overline{\ln A_{ij}}$ 等) を与えなければならないが、計算の 1 ステップ目では、乱数等で適当に与えればよい。反復計算中は、直前の M-step で得られた値を用いる。

1.3.2 M-step

各パラメータについて分布関数 q を更新し、期待値を求める。

$\mathbf{X}, \mathbf{Z}, \theta$ の同時分布は、

$$p(\mathbf{X}, \mathbf{Z}, \theta | K) = p(\theta | K) \times p(\mathbf{X}, \mathbf{Z} | \theta, K) \quad (1.56)$$

$$= p(\theta | K) \times p(\mathbf{z}_1 | \theta, K) \times \prod_{n=2}^N p(\mathbf{z}_n | \mathbf{z}_{n-1}, \theta, K) \\ \times \prod_{m=1}^N p(x_m | \mathbf{z}_m, \theta, K) \quad (1.57)$$

と書けるので、 \mathbf{Z} を固定する平均場近似を用いて

$$\ln q^*(\theta) = \mathbb{E}_{\mathbf{Z}} \left[\ln p(\theta) + \ln p(\mathbf{z}_1) + \sum_{n=2}^N \ln p(\mathbf{z}_n | \mathbf{z}_{n-1}) \right. \\ \left. + \sum_{m=1}^N \ln p(x_m | \mathbf{z}_m) \right] \quad (1.58)$$

により q^* を得る。

パラメータ π , \mathbf{A} , ϕ がそれぞれ独立、かつ、 $p(x_m|\mathbf{z}_m, \theta, K)$ は π , \mathbf{A} に依存しないとすると、まず π に関して、

$$\ln q^*(\pi) = \ln p(\pi) + \mathbb{E}_{\mathbf{Z}} [\ln p(\mathbf{z}_1)] + \text{const.} \quad (1.59)$$

$$= \ln p(\pi) + \mathbb{E}_{\mathbf{Z}} \left[\sum_i^K z_{1i} \ln \pi_i \right] + \text{const.} \quad (1.60)$$

$$= \ln p(\pi) + \sum_i^K \overline{z_{1i}} \cdot \ln \pi_i + \text{const.} \quad (1.61)$$

となり、

$$q^*(\pi) \propto p(\pi) \times \prod_i^K \pi_i^{\overline{z_{1i}}} \quad (1.62)$$

ここで、事前分布として Dirichlet 分布 $p(\pi) \propto \prod_i^K \pi_i^{(u_i^\pi - 1)}$ を与えて規格化して、

$$q^*(\pi) = \frac{\Gamma(u_0^\pi + 1)}{\prod_i^K \Gamma(u_i^\pi + \overline{z_{1i}})} \prod_i^K \pi_i^{(u_i^\pi + \overline{z_{1i}} - 1)} \quad (1.63)$$

ただし、 u_i^π は Dirichlet 分布のハイパーパラメータ。特に理由が無ければ、 $u_i^\pi = 1$ としておけばよい。

Dirichlet 分布の性質から、期待値

$$\overline{\pi_i} = \frac{u_i^\pi + \overline{z_{1i}}}{u_0^\pi + 1} \quad (1.64)$$

$$\overline{\ln \pi_i} = \psi(u_i^\pi + \overline{z_{1i}}) - \psi(u_0^\pi + 1) \quad (1.65)$$

を得る。ただし、 $u_0^\pi = \sum_i^K u_i^\pi$ 、 $\psi(x) = \frac{d}{dx} \ln \Gamma(x) = \frac{\Gamma'(x)}{\Gamma(x)}$ は digamma 関数。

次に \mathbf{A} に関して、

$$\ln q^*(\mathbf{A}) = \ln p(\mathbf{A}) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{n=2}^N \ln p(\mathbf{z}_n | \mathbf{z}_{n-1}) \right] + \text{const.} \quad (1.66)$$

$$= \ln p(\mathbf{A}) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{n=2}^N \sum_i^K \sum_j^K z_{n-1,i} z_{nj} \ln A_{ij} \right] + \text{const.} \quad (1.67)$$

$$= \ln p(\mathbf{A}) + \sum_{n=2}^N \sum_i^K \sum_j^K \overline{z_{n-1,i} z_{nj}} \cdot \ln A_{ij} + \text{const.} \quad (1.68)$$

となり、

$$q^*(\mathbf{A}) \propto p(\mathbf{A}) \times \prod_i^K \prod_j^K A_{ij}^{N_{ij}} \quad (1.69)$$

となる。ただし、 $N_{ij} = \sum_{n=2}^N \overline{z_{n-1,i} z_{nj}}$ 。ここで、事前分布として各 i での j に関する Dirichlet 分布 $p(\mathbf{A}_i) \propto \prod_j^K A_{ij}^{(u_{ij}^A - 1)}$ を与えて規格化して、

$$q^*(\mathbf{A}_i) = \frac{\Gamma(u_{i0}^A + M_i)}{\prod_j \Gamma(u_{ij}^A + N_{ij})} \prod_j^K A_{ij}^{(u_{ij}^A + N_{ij} - 1)} \quad (1.70)$$

を得る。ただし、 u_{ij}^A は Dirichlet 分布のハイパーパラメータ、 $u_{i0}^A = \sum_j^K u_{ij}^A$, $M_i = \sum_j^K N_{ij} = \sum_{n=2}^N \sum_j^K \overline{z_{n-1,i} z_{nj}}$ 。
Dirichlet 分布の性質から、期待値

$$\overline{A_{ij}} = \frac{u_{ij}^A + N_{ij}}{u_{i0}^A + M_i} \quad (1.71)$$

$$\ln \overline{A_{ij}} = \psi(u_{ij}^A + N_{ij}) - \psi(u_{i0}^A + M_i) \quad (1.72)$$

を得る。

ϕ に関しては、 $p(x_n | \mathbf{z}_n)$ の関数形に依存する。同様に適宜計算。

1.3.3 変分下限 $\mathcal{L}(q)$ の算出

変分下限 $\mathcal{L}(q)$ の計算において、 \mathbf{Z}, θ が独立であると見なせる場合、式 (1.16) は、

$$\mathcal{L}(q) = \mathbb{E}[\ln p(\theta)] - \mathbb{E}[\ln q(\theta)] + \mathbb{E}[\ln p(\mathbf{X}, \mathbf{Z} | \theta)] - \mathbb{E}[\ln q(\mathbf{Z})] \quad (1.73)$$

$$= \mathbb{E}[\ln p(\theta)] - \mathbb{E}[\ln q(\theta)] + \sum_{n=1}^N \ln \tilde{c}_n \quad (1.74)$$

ただし \tilde{c}_n は、 $\tilde{p}(\mathbf{z}_1)$, $\tilde{p}(\mathbf{z}_n | \mathbf{z}_{n-1})$, $\tilde{p}(x_m | \mathbf{z}_m)$ を用いて α - β アルゴリズムを実行した際に得られるスケーリング係数であり、E-step の計算過程で既に得られている。

式 (1.74) を既知のパラメータについて書き下すと、

$$\begin{aligned} \mathcal{L}(q) = & \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\phi)] \\ & - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\phi)] + \sum_{n=1}^N \ln \tilde{c}_n \end{aligned} \quad (1.75)$$

となるので、その他のパラメータに関して必要な項をそれぞれ計算する。

$\mathbb{E}[\ln p(\boldsymbol{\pi})]$: $\boldsymbol{\pi}$ の事前分布は Dirichlet 分布で与えられるので、

$$\mathbb{E}[\ln p(\boldsymbol{\pi})] = \mathbb{E}_{\boldsymbol{\pi}}[\ln p(\boldsymbol{\pi})] \quad (1.76)$$

$$= \mathbb{E}_{\boldsymbol{\pi}} \left[\ln \left\{ \frac{\Gamma(u_0^\pi)}{\prod_i^K \Gamma(u_i^\pi)} \prod_i^K \pi_i^{u_i^\pi - 1} \right\} \right] \quad (1.77)$$

$$= \mathbb{E}_{\boldsymbol{\pi}} \left[\left\{ \ln \Gamma(u_0^\pi) - \sum_i^K \ln \Gamma(u_i^\pi) + \sum_i^K (u_i^\pi - 1) \cdot \ln \pi_i \right\} \right] \quad (1.78)$$

$$= \ln \Gamma(u_0^\pi) + \sum_i^K \left\{ (u_i^\pi - 1) \cdot \overline{\ln \pi_i} - \ln \Gamma(u_i^\pi) \right\} \quad (1.79)$$

$\mathbb{E}[\ln p(\mathbf{A})]$: \mathbf{A} についても、事前分布は Dirichlet 分布で与えられるので、

$$\mathbb{E}[\ln p(\mathbf{A})] = \mathbb{E}_{\mathbf{A}}[\ln p(\mathbf{A})] \quad (1.80)$$

$$= \mathbb{E}_{\mathbf{A}} \left[\ln \left\{ \prod_i^K \left(\frac{\Gamma(u_{i0}^A)}{\prod_j^K \Gamma(u_{ij}^A)} \prod_j^K A_{ij}^{u_{ij}^A - 1} \right) \right\} \right] \quad (1.81)$$

$$= \mathbb{E}_{\mathbf{A}} \left[\sum_i^K \left\{ \ln \Gamma(u_{i0}^A) - \sum_j^K \ln \Gamma(u_{ij}^A) + \sum_j^K (u_{ij}^A - 1) \ln A_{ij} \right\} \right] \quad (1.82)$$

$$= \sum_i^K \left[\ln \Gamma(u_{i0}^A) + \sum_j^K \left\{ (u_{ij}^A - 1) \cdot \overline{\ln A_{ij}} - \ln \Gamma(u_{ij}^A) \right\} \right] \quad (1.83)$$

$\mathbb{E}[\ln q(\boldsymbol{\pi})]$: $q(\boldsymbol{\pi}) = \text{Dir}(\pi_i | u_i^\pi + \overline{z_{1i}})$ なので、Dirichlet 分布の性質から、

$$\mathbb{E}[\ln q(\boldsymbol{\pi})] = \mathbb{E}_{\boldsymbol{\pi}}[\ln q(\boldsymbol{\pi})] \quad (1.84)$$

$$= \sum_i^K \left[(u_i^\pi + \overline{z_{1i}} - 1) \left\{ \psi(u_i^\pi + \overline{z_{1i}}) - \psi \left(u_0^\pi + \sum_i^K \overline{z_{1i}} \right) \right\} \right] \\ + \ln \left\{ \frac{\Gamma(u_0^\pi + \sum_i^K \overline{z_{1i}})}{\prod_i^K \Gamma(u_i^\pi + \overline{z_{1i}})} \right\} \quad (1.85)$$

$$= \ln \Gamma(u_0^\pi + 1) + \sum_i^K \left[(u_i^\pi + \overline{z_{1i}} - 1) \left\{ \psi(u_i^\pi + \overline{z_{1i}}) \right. \right. \\ \left. \left. - \psi(u_0^\pi + 1) \right\} - \ln \Gamma(u_i^\pi + \overline{z_{1i}}) \right] \quad (1.86)$$

$\mathbb{E}[\ln q(\mathbf{A})]$: $q(\mathbf{A}_i) = \text{Dir}(A_{ij}|u_{ij}^A + N_{ij})$ なので、Dirichlet 分布の性質から、

$$\mathbb{E}[\ln q(\mathbf{A})] = \mathbb{E}_A[\ln q(\mathbf{A})] \quad (1.87)$$

$$= \sum_i^K \mathbb{E}_{A_i}[\ln q(\mathbf{A}_i)] \quad (1.88)$$

$$= \sum_i^K \left[\sum_j^K \left\{ (u_{ij}^A + N_{ij} - 1) [\psi(u_{ij}^A + N_{ij}) - \psi(u_{i0}^A + M_i)] \right\} \right. \\ \left. + \ln \left\{ \frac{\Gamma(u_{i0}^A + M_i)}{\prod_j^K \Gamma(u_{ij}^A + N_{ij})} \right\} \right] \quad (1.89)$$

$$= \sum_i^K \left[\ln \Gamma(u_{i0}^A + M_i) \right. \\ \left. + \sum_j^K \left\{ (u_{ij}^A + N_{ij} - 1) [\psi(u_{ij}^A + N_{ij}) - \psi(u_{i0}^A + M_i)] \right. \right. \\ \left. \left. - \ln \Gamma(u_{ij}^A + N_{ij}) \right\} \right] \quad (1.90)$$

$\mathbb{E}[\ln p(\phi)], \mathbb{E}[\ln q(\phi)]$ については、関数形に依存するので、 π, \mathbf{A} と同様にそれぞれ計算する。

1.4 Global Hidden Markov Model の変分ベイズ解法

R 本の時系列データからグローバルに解析する方法。パラメータは共通とする。

データ \mathbf{X} が、

$$\mathbf{X} = \{\mathbf{X}^{(1)}, \mathbf{X}^{(2)}, \dots, \mathbf{X}^{(R)}\} \quad (1.91)$$

$$\mathbf{X}^{(r)} = \{x_1^{(r)}, x_2^{(r)}, \dots, x_{N(r)}^{(r)}\} \quad (1.92)$$

とする。ただし、 $1 \leq r \leq R$ 。潜在変数 \mathbf{Z} も同様に

$$\mathbf{Z} = \{\mathbf{Z}^{(1)}, \mathbf{Z}^{(2)}, \dots, \mathbf{Z}^{(R)}\} \quad (1.93)$$

$$\mathbf{Z}^{(r)} = \{\mathbf{z}_1^{(r)}, \mathbf{z}_2^{(r)}, \dots, \mathbf{z}_{N(r)}^{(r)}\} \quad (1.94)$$

に拡張する。

この時 $\mathbf{X}, \mathbf{Z}, \theta$ の同時分布は、

$$p(\mathbf{X}, \mathbf{Z}, \theta) = p(\theta) \cdot p(\mathbf{X}, \mathbf{Z}|\theta) \quad (1.95)$$

$$= p(\theta) \cdot \prod_{r=1}^R p(\mathbf{X}^{(r)}, \mathbf{Z}^{(r)}|\theta) \quad (1.96)$$

$$= p(\theta) \cdot \prod_{r=1}^R \left\{ p(\mathbf{z}_1^{(r)}|\theta) \times \prod_{n=2}^{N^{(r)}} p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}, \theta) \times \prod_{m=1}^{N^{(r)}} p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta) \right\} \quad (1.97)$$

$$(1.98)$$

$$\ln p(\mathbf{X}, \mathbf{Z}, \theta) = \ln p(\theta) + \sum_{r=1}^R \left\{ \ln p(\mathbf{z}_1^{(r)}|\theta) + \sum_{n=2}^{N^{(r)}} \ln p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}, \theta) + \sum_{m=1}^{N^{(r)}} \ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta) \right\} \quad (1.99)$$

1.4.1 E-step

θ の平均場近似で $q^*(\mathbf{Z})$ を計算すると、

$$\ln q^*(\mathbf{Z}) = \mathbb{E}_\theta \left[\sum_{r=1}^R \left\{ \ln p(\mathbf{z}_1^{(r)}|\theta) + \sum_{n=2}^{N^{(r)}} \ln p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}, \theta) + \sum_{m=1}^{N^{(r)}} \ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta) \right\} \right] + \text{const.} \quad (1.100)$$

$$\begin{aligned} &= \mathbb{E}_\theta \left[\sum_{r=1}^R \ln p(\mathbf{z}_1^{(r)}|\theta) \right] + \mathbb{E}_\theta \left[\sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \ln p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}, \theta) \right] \\ &\quad + \mathbb{E}_\theta \left[\sum_{r=1}^R \sum_{m=1}^{N^{(r)}} \ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta) \right] + \text{const.} \end{aligned} \quad (1.101)$$

$p(\mathbf{z}_1^{(r)}|\theta) = \prod_{i=1}^K \pi_i^{z_{1i}^{(r)}}$, $p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}, \theta) = \prod_{i=1}^K \prod_{j=1}^K A_{ij}^{z_{n-1,i}^{(r)}, z_{nj}^{(r)}}$ とすると、

$$= \mathbb{E}_\pi \left[\sum_{r=1}^R \sum_{i=1}^K z_{1i}^{(r)} \ln \pi_i \right] + \mathbb{E}_A \left[\sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \sum_{i=1}^K \sum_{j=1}^K z_{n-1,i}^{(r)} z_{nj}^{(r)} \ln A_{ij} \right] \\ + \mathbb{E}_\theta \left[\sum_{r=1}^R \sum_{m=1}^{N^{(r)}} \ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta) \right] + \text{const.} \quad (1.102)$$

$$= \sum_{r=1}^R \left\{ \sum_{i=1}^K z_{1i}^{(r)} \overline{\ln \pi_i} + \sum_{n=2}^{N^{(r)}} \sum_{i=1}^K \sum_{j=1}^K z_{n-1,i}^{(r)} z_{nj}^{(r)} \overline{\ln A_{ij}} + \sum_{m=1}^{N^{(r)}} \overline{\ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta)} \right\} + \text{const.} \quad (1.103)$$

したがって、

$$q^*(\mathbf{Z}) \propto \prod_{r=1}^R \times \left\{ \prod_{i=1}^K \exp(\overline{\ln \pi_i})^{z_{1i}^{(r)}} \times \prod_{n=2}^{N^{(r)}} \prod_{i=1}^K \prod_{j=1}^K \exp(\overline{\ln A_{ij}})^{z_{n-1,i}^{(r)} z_{nj}^{(r)}} \right. \\ \left. \times \prod_{m=1}^{N^{(r)}} \exp(\overline{\ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta)}) \right\} \quad (1.104)$$

$$(1.105)$$

各 r について独立なので、単独の HMM と同様にそれぞれ $\gamma^{(r)}, \xi^{(r)}$ を求める。

1.4.2 M-step

各パラメータについて分布関数 q を更新し、期待値を求める。

$\mathbf{X}, \mathbf{Z}, \theta$ の同時分布

$$p(\mathbf{X}, \mathbf{Z}, \theta) = p(\theta) \cdot p(\mathbf{X}, \mathbf{Z}|\theta) \quad (1.106)$$

$$= p(\theta) \cdot \prod_{r=1}^R \left\{ p(\mathbf{X}^{(r)}, \mathbf{Z}^{(r)}|\theta) \right\} \quad (1.107)$$

$$= p(\theta) \cdot \prod_{r=1}^R \left\{ p(\mathbf{z}_1^{(r)}|\theta) \times \prod_{n=2}^{N^{(r)}} p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}, \theta) \times \prod_{m=1}^{N^{(r)}} p(x_m^{(r)}|\mathbf{z}_m^{(r)}, \theta) \right\} \quad (1.108)$$

から、 \mathbf{Z} を固定する平均場近似を用いて

$$\ln q^*(\theta) = \mathbb{E}_{\mathbf{Z}} \left[\ln p(\theta) + \sum_{r=1}^R \left\{ \ln p(\mathbf{z}_1^{(r)}) + \sum_{n=2}^N \ln p(\mathbf{z}_n^{(r)}|\mathbf{z}_{n-1}^{(r)}) + \sum_{m=1}^N \ln p(x_m^{(r)}|\mathbf{z}_m^{(r)}) \right\} \right] \quad (1.109)$$

により q^* を得る。

パラメータ π, \mathbf{A}, ϕ がそれぞれ独立、かつ、 $p(x_m^{(r)} | \mathbf{z}_m^{(r)}, \theta)$ は π, \mathbf{A} に依存しないとすると、まず π に関して、

$$\ln q^*(\pi) = \ln p(\pi) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{r=1}^R \ln p(\mathbf{z}_1^{(r)}) \right] + \text{const.} \quad (1.110)$$

$$= \ln p(\pi) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{r=1}^R \sum_i^K z_{1i}^{(r)} \ln \pi_i \right] + \text{const.} \quad (1.111)$$

$$= \ln p(\pi) + \sum_i^K \left(\sum_r^R \overline{z_{1i}^{(r)}} \right) \ln \pi_i + \text{const.} \quad (1.112)$$

となり、

$$q^*(\pi) \propto p(\pi) \times \prod_i^K \pi_i^{\overline{z_{1i}^R}} \quad (1.113)$$

ただし、 $\overline{z_{1i}^R} = \sum_r^R \overline{z_{1i}^{(r)}}$ 。ここで、事前分布として Dirichlet 分布 $p(\pi) \propto \prod_i^K \pi_i^{(u_i^\pi - 1)}$ を与えて規格化して、

$$q^*(\pi) = \frac{\Gamma(u_0^\pi + R)}{\prod_i^K \Gamma(u_i^\pi + \overline{z_{1i}^R})} \prod_i^K \pi_i^{(u_i^\pi + \overline{z_{1i}^R} - 1)} \quad (1.114)$$

ただし、 u_i^π は Dirichlet 分布のハイパーパラメータ。特に理由が無ければ、 $u_i^\pi = 1$ としておけばよい。

Dirichlet 分布の性質から、期待値

$$\overline{\pi_i} = \frac{u_i^\pi + \overline{z_{1i}^R}}{u_0^\pi + R} \quad (1.115)$$

$$\overline{\ln \pi_i} = \psi(u_i^\pi + \overline{z_{1i}^R}) - \psi(u_0^\pi + R) \quad (1.116)$$

を得る。

次に \mathbf{A} に関して、

$$\ln q^*(\mathbf{A}) = \ln p(\mathbf{A}) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \ln p(\mathbf{z}_n^{(r)} | \mathbf{z}_{n-1}^{(r)}) \right] + \text{const.} \quad (1.117)$$

$$= \ln p(\mathbf{A}) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \sum_i^K \sum_j^K z_{n-1,i}^{(r)} z_{n,j}^{(r)} \ln A_{ij} \right] + \text{const.} \quad (1.118)$$

$$= \ln p(\mathbf{A}) + \sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \sum_i^K \sum_j^K \overline{z_{n-1,i}^{(r)} z_{n,j}^{(r)}} \cdot \ln A_{ij} + \text{const.} \quad (1.119)$$

となり、

$$q^*(\mathbf{A}) \propto p(\mathbf{A}) \times \prod_i^K \prod_j^K A_{ij}^{N_{ij}^R} \quad (1.120)$$

となる。ただし、 $N_{ij}^R = \sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \overline{z_{n-1,i}^{(r)} z_{n,j}^{(r)}}$ 。ここで、事前分布として各 i での j に関する Dirichlet 分布 $p(\mathbf{A}_i) \propto \prod_j^K A_{ij}^{(u_{ij}^A - 1)}$ を与えて規格化して、

$$q^*(\mathbf{A}_i) = \frac{\Gamma(u_{i0}^A + M_i)}{\prod_j^K \Gamma(u_{ij}^A + N_{ij}^R)} \prod_j^K A_{ij}^{(u_{ij}^A + N_{ij}^R - 1)} \quad (1.121)$$

を得る。ただし、 u_{ij}^A は Dirichlet 分布のハイパーパラメータ、 $u_{i0}^A = \sum_j^K u_{ij}^A$ 、 $M_i^R = \sum_j^K N_{ij}^R = \sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \sum_j^K \overline{z_{n-1,i}^{(r)} z_{n,j}^{(r)}}$ 。

Dirichlet 分布の性質から、期待値

$$\overline{A_{ij}} = \frac{u_{ij}^A + N_{ij}^R}{u_{i0}^A + M_i^R} \quad (1.122)$$

$$\ln \overline{A_{ij}} = \psi(u_{ij}^A + N_{ij}^R) - \psi(u_{i0}^A + M_i^R) \quad (1.123)$$

を得る。

ϕ に関しては、 $p(x_m^{(r)} | \mathbf{z}_m^{(r)})$ の関数形に依存するが、 r に関して独立な場合には、一般化できる。

$$\ln q^*(\phi) = \ln p(\phi) + \mathbb{E}_{\mathbf{Z}} \left[\sum_{r=1}^R \sum_{m=1}^{N^{(r)}} \ln p(x_m^{(r)} | \mathbf{z}_m^{(r)}, \phi) \right] + \text{const.} \quad (1.124)$$

$$= \ln p(\phi) + \sum_{r=1}^R \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^{N^{(r)}} \ln p(x_m^{(r)} | \mathbf{z}_m^{(r)}, \phi) \right] + \text{const.} \quad (1.125)$$

各 r について、単独の HMM と同様に $\ln q^*(\phi)$ を求めて (事前分布は除いて) 和をとればよい (?)。

1.4.3 変分下限 $\mathcal{L}(q)$ の算出

式 (1.74) を既知のパラメータについて書き下すと、

$$\begin{aligned} \mathcal{L}(q) = & \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\phi)] + \mathbb{E}[\ln p(\mathbf{X}, \mathbf{Z}|\phi)] \\ & - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\phi)] - \mathbb{E}[\ln q(\mathbf{Z})] \end{aligned} \quad (1.126)$$

$$\begin{aligned} = & \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\phi)] + \mathbb{E} \left[\sum_{r=1}^R \ln p(\mathbf{X}^{(r)}, \mathbf{Z}^{(r)}|\phi) \right] \\ & - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\phi)] - \mathbb{E} \left[\sum_{r=1}^R \ln q(\mathbf{Z}^{(r)}) \right] \end{aligned} \quad (1.127)$$

$$\begin{aligned} = & \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\phi)] \\ & - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\phi)] + \sum_{r=1}^R \sum_{n=1}^N \ln \tilde{c}_n^{(r)} \end{aligned} \quad (1.128)$$

となるので、その他のパラメータに関して必要な項をそれぞれ計算する。

$\mathbb{E}[\ln q(\boldsymbol{\pi})]$: $q(\boldsymbol{\pi}) = \text{Dir}(\pi_i | u_i^\pi + \overline{z_{1i}^R})$ なので、Dirichlet 分布の性質から、

$$\mathbb{E}[\ln q(\boldsymbol{\pi})] = \mathbb{E}_\pi[\ln q(\boldsymbol{\pi})] \quad (1.129)$$

$$\begin{aligned} = & \sum_i^K \left[(u_i^\pi + \overline{z_{1i}^R} - 1) \left\{ \psi(u_i^\pi + \overline{z_{1i}^R}) - \psi \left(u_0^\pi + \sum_i^K \overline{z_{1i}^R} \right) \right\} \right] + \ln \left\{ \frac{\Gamma(u_0^\pi + \sum_i^K \overline{z_{1i}^R})}{\prod_i^K \Gamma(u_i^\pi + \overline{z_{1i}^R})} \right\} \end{aligned} \quad (1.130)$$

$$\begin{aligned} = & \ln \Gamma(u_0^\pi + R) + \sum_i^K \left[(u_i^\pi + \overline{z_{1i}^R} - 1) \{ \psi(u_i^\pi + \overline{z_{1i}^R}) - \psi(u_0^\pi + R) \} - \ln \Gamma(u_i^\pi + \overline{z_{1i}^R}) \right] \end{aligned} \quad (1.131)$$

$\mathbb{E}[\ln q(\mathbf{A})]$: $q(\mathbf{A}_i) = \text{Dir}(A_{ij}|u_{ij}^A + N_{ij}^R)$ なので、Dirichlet 分布の性質から、

$$\mathbb{E}[\ln q(\mathbf{A})] = \mathbb{E}_A[\ln q(\mathbf{A})] \quad (1.132)$$

$$= \sum_i^K \mathbb{E}_{A_i}[\ln q(\mathbf{A}_i)] \quad (1.133)$$

$$= \sum_i^K \left[\sum_j^K \left\{ (u_{ij}^A + N_{ij}^R - 1) \left[\psi(u_{ij}^A + N_{ij}^R) - \psi(u_{i0}^A + M_i^R) \right] \right\} \right. \\ \left. + \ln \left\{ \frac{\Gamma(u_{i0}^A + M_i^R)}{\prod_j^K \Gamma(u_{ij}^A + N_{ij}^R)} \right\} \right] \quad (1.134)$$

$$= \sum_i^K \left[\ln \Gamma(u_{i0}^A + M_i^R) + \sum_j^K \left\{ (u_{ij}^A + N_{ij}^R - 1) \left[\psi(u_{ij}^A + N_{ij}^R) - \psi(u_{i0}^A + M_i^R) \right] \right. \right. \\ \left. \left. - \ln \Gamma(u_{ij}^A + N_{ij}^R) \right\} \right] \quad (1.135)$$

Chapter 2

Gaussian Time Series

2.1 汎用 Gauss 分布

2.1.1 Gaussian 信号

m 番目の時間ビンでの信号を x_m とする。状態 i の平均を μ_i 、精度 $\lambda_i (\equiv \sigma_i^{-2})$ とすると、 $p(x_m | \mathbf{z}_m)$ は Gauss 分布

$$\begin{aligned} p(x_m | \mathbf{z}_m) &= \prod_{i=1}^K \left\{ \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp \left(-\frac{(x_m - \mu_i)^2}{2\sigma_i^2} \right) \right\}^{z_{mi}} \\ &= \prod_{i=1}^K \left\{ \sqrt{\frac{\lambda_i}{2\pi}} \exp \left(-\frac{\lambda_i}{2} (x_m - \mu_i)^2 \right) \right\}^{z_{mi}} \end{aligned} \quad (2.1)$$

で与えられる。

状態遷移確率を、遷移確率行列 \mathbf{A} で与えることにすると、 $\mathbf{X}, \mathbf{Z}, \theta$ の同時分布は、

$$\begin{aligned} p(\mathbf{X}, \mathbf{Z}, \theta) &= p(\theta) \cdot \prod_i^K \pi^{z_{1i}} \cdot \prod_{n=2}^N \prod_i^K \prod_j^K A_{ij}^{z_{n-1,i} z_{nj}} \\ &\quad \times \prod_{m=1}^N \prod_{i=1}^K \left\{ \sqrt{\frac{\lambda_i}{2\pi}} \exp \left(-\frac{\lambda_i}{2} (x_m - \mu_i)^2 \right) \right\}^{z_{mi}} \end{aligned} \quad (2.2)$$

となる。

2.1.2 E-step :

$$\ln p(x_m | \mathbf{z}_m, \mu_i, \lambda_i) = \ln \left\{ \sqrt{\frac{\lambda_i}{2\pi}} \exp \left(-\frac{\lambda_i}{2} (x_m - \mu_i)^2 \right) \right\} \quad (2.3)$$

$$= \frac{1}{2} \left\{ \ln \lambda_i - \ln 2\pi - \lambda_i (x_m - \mu_i)^2 \right\} \quad (2.4)$$

$$\overline{\ln p(x_m | \mathbf{z}_m, \mu_i, \lambda_i)} = \frac{1}{2} \left(\overline{\ln \lambda_i} - \ln 2\pi - \overline{\lambda_i (x_m - \mu_i)^2} \right) \quad (2.5)$$

式 (1.55) に式 (2.1) を適用し、

$$\tilde{p}(x_m | \mathbf{z}_m) = \prod_i^K \left\{ \frac{1}{\sqrt{2\pi}} \exp \left(\frac{1}{2} \left[\overline{\ln \lambda_i} - \overline{\lambda_i (x_m - \mu_i)^2} \right] \right) \right\}^{z_{mi}} \quad (2.6)$$

後で得られる μ_{0i} , β_i^μ , a_i^λ , b_i^λ を使って

$$= \prod_i^K \left\{ \frac{1}{\sqrt{2\pi}} \exp \left(\frac{1}{2} \left[\overline{\ln \lambda_i} - \frac{1}{\beta_i^\mu} - \frac{a_i^\lambda}{b_i^\lambda} (x_m - \mu_{0i})^2 \right] \right) \right\}^{z_{mi}} \quad (2.7)$$

を得る。

これを、式 (1.53), (1.54) とともに用いて forward-backward アルゴリズムを実行し、 γ, ξ 分布を得る。

2.1.3 M-step :

π, \mathbf{A} に関しては、1.3 節と同様に式 (1.64–1.65, 1.71–1.72) を用いて期待値を求める。

μ, λ に関しては独立でないので、各 i に関しては独立として、Gauss-Gamma 事前分布

$$p(\mu_i, \lambda_i) = \mathcal{N} \left(\mu_i | u_i^\mu, (u_i^\beta \lambda_i)^{-1} \right) \text{Gam}(\lambda_i | u_i^a, u_i^b) \quad (2.8)$$

を与えて (ただし、 $u_i^\mu, u_i^\beta, u_i^a, u_i^b$ はハイパーパラメータ)、

$$\begin{aligned} \ln q^*(\mu_i, \lambda_i) &= \ln \mathcal{N} \left(\mu_i | u_i^\mu, (u_i^\beta \lambda_i)^{-1} \right) + \ln \text{Gam}(\lambda_i | u_i^a, u_i^b) \\ &\quad + \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \cdot \ln \mathcal{N}(x_m | \mu_i, \lambda_i^{-1}) \right] + \text{const.} \end{aligned} \quad (2.9)$$

μ_i, λ_i に依存する項だけ取り出すと、

$$\begin{aligned}
&= \frac{1}{2} \ln \lambda_i - \frac{u_i^\beta \lambda_i}{2} (\mu_i - u_i^\mu)^2 + (u_i^a - 1) \ln \lambda_i - u_i^b \lambda_i \\
&\quad + \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \cdot \frac{1}{2} \left\{ \ln \lambda_i - \lambda_i (x_m - \mu_i)^2 \right\} \right] + \text{const.}
\end{aligned} \tag{2.10}$$

$\ln q^*(\mu_i, \lambda_i)$ は $\ln q^*(\mu_i | \lambda_i) + \ln q^*(\lambda_i)$ と書けるので、 μ_i に依存する項だけ考えると、

$$\begin{aligned}
\ln q^*(\mu_i | \lambda_i) &= - \frac{u_i^\beta \lambda_i}{2} (\mu_i^2 - 2u_i^\mu \mu_i) \\
&\quad - \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \cdot \frac{\lambda_i}{2} (\mu_i^2 - 2x_m \mu_i) \right] + \text{const.}
\end{aligned} \tag{2.11}$$

$$\begin{aligned}
&= - \frac{\lambda_i}{2} \left(u_i^\beta + \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \right] \right) \mu_i^2 \\
&\quad + \lambda_i \left(u_i^\beta u_i^\mu + \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} x_m \right] \right) \mu_i + \text{const.}
\end{aligned} \tag{2.12}$$

$$\begin{aligned}
&= - \frac{\lambda_i}{2} \left(u_i^\beta + \sum_{m=1}^N \overline{z_{mi}} \right) \mu_i^2 \\
&\quad + \lambda_i \left(u_i^\beta u_i^\mu + \sum_{m=1}^N \overline{z_{mi}} x_m \right) \mu_i + \text{const.}
\end{aligned} \tag{2.13}$$

$$= - \frac{\lambda_i}{2} (u_i^\beta + N_i) \mu_i^2 + \lambda_i (u_i^\beta u_i^\mu + N_i \bar{x}_i) \mu_i + \text{const.} \tag{2.14}$$

ただし、 $N_i = \sum_m \overline{z_{mi}}$ 、 $\bar{x}_i = \frac{1}{N_i} \sum_m \overline{z_{mi}} \cdot x_m$ 。

$\ln q^*(\mu_i | \lambda_i)$ が μ_i の二乗に依存しているので、 $q^*(\mu_i | \lambda_i)$ は Gauss 分布。平方完成から、

$$\beta_i^\mu = u_i^\beta + N_i \tag{2.15}$$

$$\mu_{0i} = \frac{1}{\beta_i^\mu} \left(u_i^\beta u_i^\mu + N_i \bar{x}_i \right) \tag{2.16}$$

を使って、

$$\ln q^*(\mu_i | \lambda_i) = - \frac{\beta_i^\mu \lambda_i}{2} \mu_i^2 + \beta_i^\mu \lambda_i \mu_{0i} \cdot \mu_i + \text{const.} \tag{2.17}$$

$$= - \frac{\beta_i^\mu \lambda_i}{2} (\mu_i - \mu_{0i})^2 + \text{const.} \tag{2.18}$$

$$q^*(\mu_i|\lambda_i) \propto \exp\left(-\frac{\beta_i^\mu \lambda_i}{2} (\mu_i - \mu_{0i})^2\right) \quad (2.19)$$

$$\equiv \mathcal{N}\left(\mu_i|\mu_{0i}, (\beta_i^\mu \lambda_i)^{-1}\right) \quad (2.20)$$

を得る。

$q^*(\lambda_i)$ に関しては、

$$\ln q^*(\lambda_i) = \ln q^*(\mu_i, \lambda_i) - \ln q^*(\mu_i|\lambda_i) \quad (2.21)$$

の関係から、式 (2.10) と式 (2.20) を使って、

$$\begin{aligned} \ln q^*(\lambda_i) &= \frac{1}{2} \ln \lambda_i - \frac{u_i^\beta \lambda_i}{2} (\mu_i - u_i^\mu)^2 + (u_i^a - 1) \ln \lambda_i - u_i^b \lambda_i \\ &\quad + \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \cdot \frac{1}{2} \left\{ \ln \lambda_i - \lambda_i (x_m - \mu_i)^2 \right\} \right] \\ &\quad - \left\{ \frac{1}{2} \ln \lambda_i - \frac{\beta_i^\mu \lambda_i}{2} (\mu_i - \mu_{0i})^2 \right\} + \text{const.} \end{aligned} \quad (2.22)$$

λ_i に依存する項だけ取り出して、

$$\begin{aligned} \ln q^*(\lambda_i) &= \left(u_i^a - 1 + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \right] \right) \ln \lambda_i - \left\{ \frac{u_i^\beta}{2} (\mu_i - u_i^\mu)^2 + u_i^b \right. \\ &\quad \left. + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} (x_m - \mu_i)^2 \right] - \frac{\beta_i^\mu}{2} (\mu_i - \mu_{0i})^2 \right\} \lambda_i + \text{const.} \end{aligned} \quad (2.23)$$

$$= (a_i^\lambda - 1) \ln \lambda_i - b_i^\lambda \lambda_i + \text{const.} \quad (2.24)$$

ただし、

$$a_i^\lambda = u_i^a + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \right] + \frac{1}{2} \quad (2.25)$$

$$= u_i^a + \frac{N_i}{2} \quad (2.26)$$

$$\begin{aligned} b_i^\lambda &= u_i^b + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} (x_m - \mu_i)^2 \right] + \frac{u_i^\beta}{2} (\mu_i - u_i^\mu)^2 \\ &\quad - \frac{u_i^\beta + N_i}{2} \left(\mu_i - \frac{u_i^\beta u_i^\mu + N_i \bar{x}_i}{u_i^\beta + N_i} \right)^2 \end{aligned} \quad (2.27)$$

$$\begin{aligned}
&= u_i^b + \frac{1}{2} \sum_{m=1}^N \overline{z_{mi}} (x_m^2 - 2\mu_i x_m + \mu_i^2) + \frac{u_i^\beta}{2} (\mu_i^2 - 2u_i^\mu \mu_i + u_i^{\mu 2}) \\
&\quad - \frac{u_i^\beta + N_i}{2} \left\{ \mu_i^2 - 2 \frac{u_i^\beta u_i^\mu + N_i \bar{x}_i}{u_i^\beta + N_i} \mu_i + \left(\frac{u_i^\beta u_i^\mu + N_i \bar{x}_i}{u_i^\beta + N_i} \right)^2 \right\}
\end{aligned} \tag{2.28}$$

$$\begin{aligned}
&= u_i^b + \frac{1}{2} \sum_{m=1}^N \overline{z_{mi}} (x_m^2 - 2\bar{x}_i x_m + \bar{x}_i^2) \\
&\quad - \frac{1}{2} \sum_{m=1}^N \overline{z_{mi}} (\bar{x}_i^2 - 2\bar{x}_i x_m + 2\mu_i x_m - \mu_i^2) - \frac{N_i}{2} \mu_i^2 \\
&\quad - \left\{ u_i^\beta u_i^\mu - \left(u_i^\beta u_i^\mu + N_i \bar{x}_i \right) \right\} \mu_i + \frac{u_i^\beta u_i^{\mu 2}}{2} \\
&\quad - \frac{u_i^\beta + N_i}{2} \left(\frac{u_i^\beta u_i^\mu + N_i \bar{x}_i}{u_i^\beta + N_i} \right)^2
\end{aligned} \tag{2.29}$$

$$\begin{aligned}
&= u_i^b + \frac{N_i}{2} \mathbf{S}_i - \frac{1}{2} (N_i \bar{x}_i^2 - 2N_i \bar{x}_i^2 + 2N_i \mu_i \bar{x}_i - N_i \mu_i^2) - \frac{N_i}{2} \mu_i^2 \\
&\quad + N_i \bar{x}_i \mu_i + \frac{u_i^\beta u_i^{\mu 2}}{2} - \frac{\left(u_i^\beta u_i^\mu \right)^2 + 2u_i^\beta u_i^\mu N_i \bar{x}_i + (N_i \bar{x}_i)^2}{2(u_i^\beta + N_i)}
\end{aligned} \tag{2.30}$$

$$\begin{aligned}
&= u_i^b + \frac{N_i}{2} \mathbf{S}_i + \frac{N_i}{2} \bar{x}_i^2 + \frac{u_i^\beta u_i^{\mu 2}}{2} - \frac{\left(u_i^\beta u_i^\mu \right)^2 + 2u_i^\beta u_i^\mu N_i \bar{x}_i + (N_i \bar{x}_i)^2}{2(u_i^\beta + N_i)}
\end{aligned} \tag{2.31}$$

$$\begin{aligned}
&= u_i^b + \frac{N_i}{2} \mathbf{S}_i + \frac{1}{2(u_i^\beta + N_i)} \left\{ N_i (u_i^\beta + N_i) \bar{x}_i^2 + (u_i^\beta + N_i) u_i^\beta u_i^{\mu 2} \right. \\
&\quad \left. - \left(u_i^\beta u_i^\mu \right)^2 - 2u_i^\beta u_i^\mu N_i \bar{x}_i - (N_i \bar{x}_i)^2 \right\}
\end{aligned} \tag{2.32}$$

$$= u_i^b + \frac{N_i}{2} \mathbf{S}_i + \frac{N_i u_i^\beta \bar{x}_i^2 - 2u_i^\beta u_i^\mu N_i \bar{x}_i + N_i u_i^\beta u_i^{\mu 2}}{2(u_i^\beta + N_i)} \tag{2.33}$$

$$= u_i^b + \frac{N_i}{2} \mathbf{S}_i + \frac{u_i^\beta N_i}{2(u_i^\beta + N_i)} (\bar{x}_i^2 - 2u_i^\mu \bar{x}_i + u_i^{\mu 2}) \tag{2.34}$$

$$= u_i^b + \frac{N_i}{2} \mathbf{S}_i + \frac{u_i^\beta N_i}{2(u_i^\beta + N_i)} (\bar{x}_i - u_i^\mu)^2 \tag{2.35}$$

ただし、

$$\mathbf{S}_i = \frac{1}{N_i} \sum_{m=1}^N \overline{z_{mi}} (x_m - \bar{x}_i)^2 \quad (2.36)$$

これら μ_{0i} , β_i^μ , a_i^λ , b_i^λ を使って Gauss-Gamma 分布 (??) として、

$$q^*(\mu_i, \lambda_i) = \mathcal{N}(\mu_i | \mu_{0i}, (\beta_i^\mu \lambda_i)^{-1}) \text{Gam}(\lambda_i | a_i^\lambda, b_i^\lambda) \quad (2.37)$$

$$= \sqrt{\frac{\beta_i^\mu \lambda_i}{2\pi}} \exp \left\{ -\frac{\beta_i^\mu \lambda_i}{2} (\mu_i - \mu_{0i})^2 \right\} \frac{1}{\Gamma(a_i^\lambda)} b_i^{\lambda a_i^\lambda} \lambda_i^{a_i^\lambda - 1} e^{-b_i^\lambda \lambda_i} \quad (2.38)$$

を得る。計算により、

$$\overline{\mu_i} = \mu_{0i} \quad (2.39)$$

$$\overline{\lambda_i} = \frac{a_i^\lambda}{b_i^\lambda} \quad (2.40)$$

$$\overline{\ln \lambda_i} = \psi(a_i^\lambda) - \ln b_i^\lambda \quad (2.41)$$

$$\overline{\lambda_i (x - \mu_i)^2} = \frac{1}{\beta_i^\mu} + \frac{a_i^\lambda}{b_i^\lambda} (x - \mu_{0i})^2 \quad (2.42)$$

が得られる。

2.1.4 変分下限 $\mathcal{L}(q)$ の算出

変分下限 $\mathcal{L}(q)$ を計算するため、式 (1.75) から、

$$\begin{aligned} \mathcal{L}(q) = & \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\boldsymbol{\mu}, \boldsymbol{\lambda})] \\ & - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\boldsymbol{\mu}, \boldsymbol{\lambda})] + \prod_n^N \tilde{c}_n \end{aligned} \quad (2.43)$$

を得る。

$\mathbb{E}[\ln p(\boldsymbol{\pi})]$, $\mathbb{E}[\ln p(\mathbf{A})]$, $\mathbb{E}[\ln q(\boldsymbol{\pi})]$, $\mathbb{E}[\ln q(\mathbf{A})]$ に関しては、式 (1.79), (1.83), (1.86), (1.90) で、 \tilde{c}_n に関しては E-step で、それぞれ得られているので、以下ではそれ以外の項について計算する。

$$\mathbb{E}[\ln p(\boldsymbol{\mu}, \boldsymbol{\lambda})] :$$

$$\mathbb{E}[\ln p(\boldsymbol{\mu}, \boldsymbol{\lambda})] = \mathbb{E} \left[\ln \prod_i^K \mathcal{N}(\mu_i | u_i^\mu, (u_i^\beta \lambda_i)^{-1}) \text{Gam}(\lambda_i | u_i^a, u_i^b) \right] \quad (2.44)$$

$$= \mathbb{E} \left[\ln \prod_i^K \sqrt{\frac{u_i^\beta \lambda_i}{2\pi}} \exp \left\{ -\frac{u_i^\beta \lambda_i}{2} (\mu_i - u_i^\mu)^2 \right\} \right. \\ \left. \times \frac{1}{\Gamma(u_i^a)} u_i^{b u_i^a} \lambda_i^{u_i^a - 1} e^{-u_i^b \lambda_i} \right] \quad (2.45)$$

$$= \mathbb{E} \left[\sum_i^K \left\{ \frac{1}{2} \ln u_i^\beta + \frac{1}{2} \ln \lambda_i - \frac{1}{2} \ln 2\pi - \frac{u_i^\beta}{2} \lambda_i (\mu_i - u_i^\mu)^2 \right. \right. \\ \left. \left. - \ln \Gamma(u_i^a) + u_i^a \ln u_i^b + (u_i^a - 1) \ln \lambda_i - u_i^b \lambda_i \right\} \right] \quad (2.46)$$

$$= -\frac{K}{2} \ln 2\pi + \sum_i^K \left\{ \frac{1}{2} \ln u_i^\beta - \frac{u_i^\beta}{2} \overline{\lambda_i (\mu_i - u_i^\mu)^2} \right. \\ \left. - \ln \Gamma(u_i^a) + u_i^a \ln u_i^b + \left(u_i^a - \frac{1}{2} \right) \overline{\ln \lambda_i} - u_i^b \overline{\lambda_i} \right\} \quad (2.47)$$

$$= -\frac{K}{2} \ln 2\pi + \sum_i^K \left\{ \frac{1}{2} \ln u_i^\beta - \frac{u_i^\beta}{2} \left[\frac{1}{\beta_i^\mu} + \frac{a_i^\lambda}{b_i^\lambda} (\mu_{0i} - u_i^\mu)^2 \right] \right. \\ \left. - \ln \Gamma(u_i^a) + u_i^a \ln u_i^b + \left(u_i^a - \frac{1}{2} \right) \overline{\ln \lambda_i} - u_i^b \overline{\lambda_i} \right\} \quad (2.48)$$

$$\mathbb{E}[\ln q(\boldsymbol{\mu}, \boldsymbol{\lambda})] :$$

$$\mathbb{E}[\ln q(\boldsymbol{\mu}, \boldsymbol{\lambda})] = \mathbb{E} \left[\ln \prod_i^K \mathcal{N}(\mu_i | \mu_{0i}, (\beta_i^\mu \lambda_i)^{-1}) \text{Gam}(\lambda_i | a_i^\lambda, b_i^\lambda) \right] \quad (2.49)$$

$$= \mathbb{E} \left[\ln \prod_i^K \sqrt{\frac{\beta_i^\mu \lambda_i}{2\pi}} \exp \left\{ -\frac{\beta_i^\mu \lambda_i}{2} (\mu_i - \mu_{0i})^2 \right\} \right. \\ \left. \times \frac{1}{\Gamma(a_i^\lambda)} b_i^{\lambda a_i^\lambda} \lambda_i^{a_i^\lambda - 1} e^{-b_i^\lambda \lambda_i} \right] \quad (2.50)$$

$$= \mathbb{E} \left[\sum_i^K \left\{ \frac{1}{2} \ln \beta_i^\mu + \frac{1}{2} \ln \lambda_i - \frac{1}{2} \ln 2\pi - \frac{\beta_i^\mu}{2} \lambda_i (\mu_i - \mu_{0i})^2 \right. \right. \\ \left. \left. - \ln \Gamma(a_i^\lambda) + a_i^\lambda \ln b_i^\lambda + (a_i^\lambda - 1) \ln \lambda_i - b_i^\lambda \lambda_i \right\} \right] \quad (2.51)$$

$$\begin{aligned}
&= -\frac{K}{2} \ln 2\pi + \sum_i^K \left\{ \frac{1}{2} \ln \beta_i^\mu - \frac{\beta_i^\mu}{2} \overline{\lambda_i (\mu_i - \mu_{0i})^2} \right. \\
&\quad \left. - \ln \Gamma(a_i^\lambda) + a_i^\lambda \ln b_i^\lambda + \left(a_i^\lambda - \frac{1}{2} \right) \overline{\ln \lambda_i} - b_i^\lambda \overline{\lambda_i} \right\} \quad (2.52)
\end{aligned}$$

$$\begin{aligned}
&= -\frac{K}{2} \ln 2\pi + \sum_i^K \left\{ \frac{1}{2} \ln \beta_i^\mu - \frac{\beta_i^\mu}{2} \left[\frac{1}{\beta_i^\mu} + \frac{a_i^\lambda}{b_i^\lambda} (\mu_{0i} - \mu_{0i})^2 \right] \right. \\
&\quad \left. - \ln \Gamma(a_i^\lambda) + a_i^\lambda \ln b_i^\lambda + \left(a_i^\lambda - \frac{1}{2} \right) \overline{\ln \lambda_i} - b_i^\lambda \overline{\lambda_i} \right\} \quad (2.53)
\end{aligned}$$

$$\begin{aligned}
&= -\frac{K}{2} \ln 2\pi - \frac{K}{2} + \sum_i^K \left\{ \frac{1}{2} \ln \beta_i^\mu - \ln \Gamma(a_i^\lambda) + a_i^\lambda \ln b_i^\lambda \right. \\
&\quad \left. + \left(a_i^\lambda - \frac{1}{2} \right) \overline{\ln \lambda_i} - b_i^\lambda \overline{\lambda_i} \right\} \quad (2.54)
\end{aligned}$$

$$\begin{aligned}
&= -\frac{K}{2} \ln 2\pi - \frac{K}{2} + \sum_i^K \left\{ \frac{1}{2} \ln \beta_i^\mu - \ln \Gamma(a_i^\lambda) + a_i^\lambda \ln b_i^\lambda \right. \\
&\quad \left. + \left(a_i^\lambda - \frac{1}{2} \right) \overline{\ln \lambda_i} - a_i^\lambda \right\} \quad (2.55)
\end{aligned}$$

2.1.5 global analysis 対応

M-step と lower bounds の計算で、 N_i , M_i , N_{ij} , \bar{x}_i , \mathbf{S}_i をそれぞれ

$$N_i^R = \sum_{r=1}^R \sum_m^N \overline{z_{mi}^R} \quad (2.56)$$

$$M_i^R = \sum_j^K N_{ij}^R = \sum_{r=1}^R \sum_{n=2}^{N^{(r)}} \sum_j^K \overline{z_{n-1,i}^{(r)} z_{nj}^{(r)}} \quad (2.57)$$

$$\bar{x}_i^R = \frac{1}{N_i^R} \sum_{r=1}^R \sum_m^N \overline{z_{mi}^R} \cdot x_m^R \quad (2.58)$$

$$\mathbf{S}_i^R = \frac{1}{N_i^R} \sum_{r=1}^R \sum_{m=1}^N \overline{z_{mi}^R} (x_m^R - \bar{x}_i^R)^2 \quad (2.59)$$

に置き換えて計算すればよい。

2.2 Gaussian 1 分子蛍光強度信号

蛍光 1 分子の蛍光強度が平均 μ 、分散 σ^2 (精度は $\lambda \equiv \sigma^{-2}$) の Gauss 分布

$$p(x_m|\mu, \lambda) = \mathcal{N}(x_m|\mu, \lambda) \quad (2.60)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_m - \mu)^2}{2\sigma^2}\right) \quad (2.61)$$

$$= \sqrt{\frac{\lambda}{2\pi}} \exp\left(-\frac{\lambda}{2}(x_m - \mu)^2\right) \quad (2.62)$$

で得られるとする。このとき、 i 量体 (本節では虚数単位 i は用いない) の強度は

$$p(x_m|\mu, \lambda) = \mathcal{N}(x_m|i\mu, \lambda/i) \quad (2.63)$$

$$= \sqrt{\frac{\lambda}{2\pi i}} \exp\left(-\frac{\lambda}{2i}(x_m - i\mu)^2\right) \quad (2.64)$$

になるので、emission probability は

$$p(x_m|\mathbf{z}_m, \mu, \lambda) = \prod_{i=1}^K \left\{ \sqrt{\frac{\lambda}{2\pi i}} \exp\left(-\frac{\lambda}{2i}(x_m - i\mu)^2\right) \right\}^{z_{mi}} \quad (2.65)$$

で与えられる。

状態遷移確率を遷移確率行列 \mathbf{A} で与えることにすると、 $\mathbf{X}, \mathbf{Z}, \theta$ の同時分布は、

$$\begin{aligned} p(\mathbf{X}, \mathbf{Z}, \theta) = & p(\theta) \times \prod_i^K \pi^{z_{1i}} \times \prod_{n=2}^N \prod_i^K \prod_j^K A_{ij}^{z_{n-1,i} z_{nj}} \\ & \times \prod_{m=1}^N \prod_{i=1}^K \left\{ \sqrt{\frac{\lambda}{2\pi i}} \exp\left(-\frac{\lambda}{2i}(x_m - i\mu)^2\right) \right\}^{z_{mi}} \end{aligned} \quad (2.66)$$

となる。

2.2.1 E-step :

$$\ln p(x_m|\mathbf{z}_m, \mu, \lambda) = \sum_{i=1}^K \ln \left\{ \sqrt{\frac{\lambda}{2\pi i}} \exp\left(-\frac{\lambda}{2i}(x_m - i\mu)^2\right) \right\}^{z_{mi}} \quad (2.67)$$

$$= \sum_{i=1}^K \frac{z_{mi}}{2} \left\{ \ln \lambda - \ln 2\pi i - \frac{\lambda}{i}(x_m - i\mu)^2 \right\} \quad (2.68)$$

$$\overline{\ln p(x_m|\mathbf{z}_m, \mu, \lambda)} = \sum_{i=1}^K \frac{z_{mi}}{2} \left(\overline{\ln \lambda} - \ln 2\pi i - \frac{1}{i} \overline{\lambda (x_m - i\mu)^2} \right) \quad (2.69)$$

式 (1.55) に式 (2.65) を適用し、

$$\tilde{p}(x_m | \mathbf{z}_m, \mu, \lambda) = \prod_i^K \left\{ \frac{1}{\sqrt{2\pi i}} \exp \left(\frac{1}{2} \left[\overline{\ln \lambda} - \frac{1}{i} \overline{\lambda (x_m - i\mu)^2} \right] \right) \right\}^{z_{mi}} \quad (2.70)$$

後で得られる $\mu_0, \beta^\mu, a^\lambda, b^\lambda$ を使って

$$= \prod_i^K \left\{ \frac{1}{\sqrt{2\pi i}} \exp \left(\frac{1}{2} \left[\overline{\ln \lambda} - \frac{i}{\beta^\mu} - \frac{a^\lambda}{b^\lambda} \frac{(x_m - i\mu_0)^2}{i} \right] \right) \right\}^{z_{mi}} \quad (2.71)$$

を得る。

これを、式 (1.53), (1.54) とともに用いて forward-backward アルゴリズムを実行し、 γ, ξ 分布を得る。

2.2.2 M-step :

π, \mathbf{A} に関しては、1.3 節と同様に式 (1.64–1.65, 1.71–1.72) を用いて期待値を求める。

μ, λ に関しては独立でなく、各 i に関しても独立ではないことに注意。
Gauss-Gamma 事前分布

$$p(\mu, \lambda) = \mathcal{N}(\mu | u^\mu, (u^\beta \lambda)^{-1}) \text{Gam}(\lambda | u^a, u^b) \quad (2.72)$$

を与えて (ただし、 u^μ, u^β, u^a, u^b はハイパーパラメータ)、

$$\begin{aligned} \ln q^*(\mu, \lambda) &= \ln \mathcal{N}(\mu | u^\mu, (u^\beta \lambda)^{-1}) + \ln \text{Gam}(\lambda | u^a, u^b) \\ &\quad + \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \cdot \ln \mathcal{N}(x_m | i\mu, i/\lambda) \right] + \text{const.} \end{aligned} \quad (2.73)$$

μ, λ に依存する項だけ取り出すと、

$$\begin{aligned} &= \frac{1}{2} \ln \lambda - \frac{u^\beta \lambda}{2} (\mu - u^\mu)^2 + (u^a - 1) \ln \lambda - u^b \lambda \\ &\quad + \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \cdot \frac{1}{2} \left\{ \ln \lambda - \frac{\lambda}{i} (x_m - i\mu)^2 \right\} \right] + \text{const.} \end{aligned} \quad (2.74)$$

$\ln q^*(\mu, \lambda)$ は $\ln q^*(\mu|\lambda) + \ln q^*(\lambda)$ と書けるので、 μ に依存する項だけ考えると、

$$\begin{aligned} \ln q^*(\mu|\lambda) = & -\frac{u^\beta \lambda}{2}(\mu^2 - 2u^\mu \mu) \\ & - \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \cdot \frac{\lambda}{2i} \{ (i\mu)^2 - 2ix_m \mu \} \right] + \text{const.} \end{aligned} \quad (2.75)$$

$$\begin{aligned} = & -\frac{\lambda}{2} \left(u^\beta + \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N iz_{mi} \right] \right) \mu^2 \\ & + \lambda \left(u^\beta u^\mu + \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} x_m \right] \right) \mu + \text{const.} \end{aligned} \quad (2.76)$$

$$\begin{aligned} = & -\frac{\lambda}{2} \left(u^\beta + \sum_{i=1}^K i \sum_{m=1}^N \overline{z_{mi}} \right) \mu^2 \\ & + \lambda \left(u^\beta u^\mu + \sum_{i=1}^K \sum_{m=1}^N \overline{z_{mi}} x_m \right) \mu + \text{const.} \end{aligned} \quad (2.77)$$

$$= -\frac{\lambda}{2} (u^\beta + N_0^i) \mu^2 + \lambda (u^\beta u^\mu + N_x) \mu + \text{const.} \quad (2.78)$$

ただし、

$$N_i = \sum_{m=1}^N \overline{z_{mi}} \quad (2.79)$$

$$N_0^i = \sum_{i=1}^K i N_i \quad (2.80)$$

$$N_x = \sum_{i=1}^K \sum_{m=1}^N \overline{z_{mi}} x_m \quad (2.81)$$

$\ln q^*(\mu|\lambda)$ が μ_i の二乗に依存しているので、 $q^*(\mu|\lambda)$ は Gauss 分布。平方完成から、

$$\beta^\mu = u^\beta + N_0^i \quad (2.82)$$

$$\mu_0 = \frac{1}{\beta^\mu} (u^\beta u^\mu + N_x) \quad (2.83)$$

を使って、

$$q^*(\mu|\lambda) = \mathcal{N}(\mu|\mu_0, (\beta^\mu \lambda)^{-1}) \quad (2.84)$$

を得る。

$q^*(\lambda)$ に関しては、

$$\ln q^*(\lambda) = \ln q^*(\mu, \lambda) - \ln q^*(\mu|\lambda) \quad (2.85)$$

の関係から、式 (2.74) と式 (2.20) を使って、 λ に依存する項だけを抜き出して、

$$\begin{aligned} \ln q^*(\lambda) &= \frac{1}{2} \ln \lambda - \frac{u^\beta \lambda}{2} (\mu - u^\mu)^2 + (u^a - 1) \ln \lambda - u^b \lambda \\ &\quad + \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \cdot \frac{1}{2} \left\{ \ln \lambda - \frac{\lambda}{i} (x_m - i\mu)^2 \right\} \right] \\ &\quad - \left\{ \frac{1}{2} \ln \lambda - \frac{\beta^\mu \lambda}{2} (\mu - \mu_0)^2 \right\} + \text{const.} \end{aligned} \quad (2.86)$$

$$\begin{aligned} &= \left(u^a - 1 + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \right] \right) \ln \lambda \\ &\quad - \left\{ \frac{u^\beta}{2} (\mu - u^\mu)^2 + u^b + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \frac{(x_m - i\mu)^2}{i} \right] \right. \\ &\quad \left. - \frac{\beta^\mu}{2} (\mu - \mu_0)^2 \right\} \lambda + \text{const.} \end{aligned} \quad (2.87)$$

$$= (a^\lambda - 1) \ln \lambda - b^\lambda \lambda + \text{const.} \quad (2.88)$$

ただし、

$$a^\lambda = u^a + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \right] \quad (2.89)$$

$$= u^a + \frac{N}{2} \quad (2.90)$$

$$\begin{aligned} b^\lambda &= u^b + \frac{1}{2} \mathbb{E}_{\mathbf{Z}} \left[\sum_{i=1}^K \sum_{m=1}^N z_{mi} \frac{(x_m - i\mu)^2}{i} \right] + \frac{u^\beta}{2} (\mu - u^\mu)^2 \\ &\quad - \frac{\beta^\mu}{2} (\mu - \mu_0)^2 \end{aligned} \quad (2.91)$$

$$\begin{aligned} &= u^b + \frac{1}{2} \left\{ \sum_{i=1}^K \sum_{m=1}^N \overline{z_{mi}} \frac{x_m^2 - 2ix_m\mu + (i\mu)^2}{i} \right\} + \frac{u^\beta}{2} (\mu - u^\mu)^2 \\ &\quad - \frac{u^\beta + N_0^i}{2} (\mu - \mu_0)^2 \end{aligned} \quad (2.92)$$

$$\begin{aligned} &= u^b + \frac{1}{2} \left\{ \sum_{i=1}^K \sum_{m=1}^N \frac{\overline{z_{mi}} x_m^2}{i} - 2\mu \sum_{i=1}^K \sum_{m=1}^N \overline{z_{mi}} x_m + \mu^2 \sum_{i=1}^K i \sum_{m=1}^N \overline{z_{mi}} \right\} \\ &\quad - \frac{N_0^i}{2} \mu^2 + \left\{ (u^\beta + N_0^i) \mu_0 - u^\beta u^\mu \right\} \mu + \frac{u^\beta}{2} u^{\mu^2} - \frac{u^\beta + N_0^i}{2} \mu_0^2 \end{aligned} \quad (2.93)$$

$$\begin{aligned}
&= u^b + \frac{1}{2} \left\{ \sum_{i=1}^K \sum_{m=1}^N \frac{\overline{z_{mi}} x_m^2}{i} - 2N_x \mu + N_0^i \mu^2 \right\} \\
&\quad - \frac{N_0^i}{2} \mu^2 + (\beta^\mu \mu_0 - u^\beta u^\mu) \mu + \frac{u^\beta}{2} u^{\mu 2} - \frac{\beta^\mu}{2} \mu_0^2
\end{aligned} \tag{2.94}$$

$$\begin{aligned}
&= u^b + \frac{1}{2} \sum_{i=1}^K \sum_{m=1}^N \frac{\overline{z_{mi}} x_m^2}{i} + \left\{ (u^\beta u^\mu + N_x) - u^\beta u^\mu - N_x \right\} \mu \\
&\quad + \frac{u^\beta}{2} u^{\mu 2} - \frac{\beta^\mu}{2} \mu_0^2
\end{aligned} \tag{2.95}$$

$$= u^b + \frac{1}{2} \sum_{i=1}^K \sum_{m=1}^N \frac{\overline{z_{mi}} x_m^2}{i} + \frac{u^\beta}{2} u^{\mu 2} - \frac{\beta^\mu}{2} \mu_0^2 \tag{2.96}$$

これら $\mu_0, \beta^\mu, a^\lambda, b^\lambda$ を使って Gauss-Gamma 分布 (??) として、

$$q^*(\mu, \lambda) = \mathcal{N} \left(\mu | \mu_0, (\beta^\mu \lambda)^{-1} \right) \text{Gam}(\lambda | a^\lambda, b^\lambda) \tag{2.97}$$

$$= \sqrt{\frac{\beta^\mu \lambda}{2\pi}} \exp \left\{ -\frac{\beta^\mu \lambda}{2} (\mu - \mu_0)^2 \right\} \frac{1}{\Gamma(a^\lambda)} b^\lambda a^\lambda \lambda^{a^\lambda - 1} e^{-b^\lambda \lambda} \tag{2.98}$$

を得る。計算により、

$$\overline{\mu} = \mu_0 \tag{2.99}$$

$$\overline{\lambda} = \frac{a^\lambda}{b^\lambda} \tag{2.100}$$

$$\overline{\ln \lambda} = \psi(a^\lambda) - \ln b^\lambda \tag{2.101}$$

$$\overline{\lambda(x - \mu)^2} = \frac{1}{\beta^\mu} + \frac{a^\lambda}{b^\lambda} (x - \mu_0)^2 \tag{2.102}$$

$$\overline{\lambda(x - i\mu)^2} = \frac{i^2}{\beta^\mu} + \frac{a^\lambda}{b^\lambda} (x - i\mu_0)^2 \tag{2.103}$$

が得られる。

2.2.3 変分下限 $\mathcal{L}(q)$ の算出

変分下限 $\mathcal{L}(q)$ を計算するため、式 (1.75) から、

$$\begin{aligned}
\mathcal{L}(q) &= \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\mu, \lambda)] \\
&\quad - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\mu, \lambda)] + \prod_n^N \tilde{c}_n
\end{aligned} \tag{2.104}$$

を得る。

$\mathbb{E}[\ln p(\boldsymbol{\pi})], \mathbb{E}[\ln p(\mathbf{A})], \mathbb{E}[\ln q(\boldsymbol{\pi})], \mathbb{E}[\ln q(\mathbf{A})]$ に関しては、式 (1.79), (1.83), (1.86), (1.90) で、 \tilde{c}_n に関しては E-step で、それぞれ得られているので、以下ではそれ以外の項について計算する。

$$\mathbb{E}[\ln p(\mu, \lambda)] :$$

$$\mathbb{E}[\ln p(\mu, \lambda)] = \mathbb{E} \left[\ln \mathcal{N} \left(\mu | u^\mu, (u^\beta \lambda)^{-1} \right) \text{Gam}(\lambda | u^a, u^b) \right] \quad (2.105)$$

$$= \mathbb{E} \left[\ln \sqrt{\frac{u^\beta \lambda}{2\pi}} \exp \left\{ -\frac{u^\beta \lambda}{2} (\mu - u^\mu)^2 \right\} \right. \\ \left. \times \frac{1}{\Gamma(u^a)} u^{bu^a} \lambda^{u^a-1} e^{-u^b \lambda} \right] \quad (2.106)$$

$$= \mathbb{E} \left[\frac{1}{2} \ln u^\beta + \frac{1}{2} \ln \lambda - \frac{1}{2} \ln 2\pi - \frac{u^\beta}{2} \lambda (\mu - u^\mu)^2 \right. \\ \left. - \ln \Gamma(u^a) + u^a \ln u^b + (u^a - 1) \ln \lambda - u^b \lambda \right] \quad (2.107)$$

$$= \frac{1}{2} \ln u^\beta - \frac{1}{2} \ln 2\pi - \frac{u^\beta}{2} \overline{\lambda (\mu - u^\mu)^2} \\ - \ln \Gamma(u^a) + u^a \ln u^b + \left(u^a - \frac{1}{2} \right) \overline{\ln \lambda} - u^b \overline{\lambda} \quad (2.108)$$

$$= \frac{1}{2} \ln u^\beta - \frac{1}{2} \ln 2\pi - \frac{u^\beta}{2} \left[\frac{1}{\beta^\mu} + \frac{a^\lambda}{b^\lambda} (\mu_0 - u^\mu)^2 \right] \\ - \ln \Gamma(u^a) + u^a \ln u^b + \left(u^a - \frac{1}{2} \right) \overline{\ln \lambda} - u^b \overline{\lambda} \quad (2.109)$$

$$\mathbb{E}[\ln q(\mu, \lambda)] :$$

$$\mathbb{E}[\ln q(\mu, \lambda)] = \mathbb{E} \left[\ln \mathcal{N} \left(\mu | \mu_0, (\beta^\mu \lambda)^{-1} \right) \text{Gam}(\lambda | a^\lambda, b^\lambda) \right] \quad (2.110)$$

$$= \mathbb{E} \left[\ln \left\{ \sqrt{\frac{\beta^\mu \lambda}{2\pi}} \exp \left(-\frac{\beta^\mu \lambda}{2} (\mu - \mu_0)^2 \right) \right. \right. \\ \left. \left. \times \frac{1}{\Gamma(a^\lambda)} b^{\lambda a^\lambda} \lambda^{a^\lambda-1} e^{-b^\lambda \lambda} \right\} \right] \quad (2.111)$$

$$= \mathbb{E} \left[\left\{ \frac{1}{2} \ln \beta^\mu + \frac{1}{2} \ln \lambda - \frac{1}{2} \ln 2\pi - \frac{\beta^\mu}{2} \lambda (\mu - \mu_0)^2 \right. \right. \\ \left. \left. - \ln \Gamma(a^\lambda) + a^\lambda \ln b^\lambda + (a^\lambda - 1) \ln \lambda - b^\lambda \lambda \right\} \right] \quad (2.112)$$

$$= \frac{1}{2} \ln \beta^\mu - \frac{1}{2} \ln 2\pi - \frac{\beta^\mu}{2} \overline{\lambda (\mu - \mu_0)^2} \\ - \ln \Gamma(a^\lambda) + a^\lambda \ln b^\lambda + \left(a^\lambda - \frac{1}{2} \right) \overline{\ln \lambda} - b^\lambda \overline{\lambda} \quad (2.113)$$

$$\begin{aligned}
&= \frac{1}{2} \ln \beta^\mu - \frac{1}{2} \ln 2\pi - \frac{\beta^\mu}{2} \left[\frac{1}{\beta^\mu} + \frac{a^\lambda}{b^\lambda} (\mu_0 - \mu_0)^2 \right] \\
&\quad - \ln \Gamma(a^\lambda) + a^\lambda \ln b^\lambda + \left(a^\lambda - \frac{1}{2} \right) \overline{\ln \lambda} - b^\lambda \bar{\lambda} \quad (2.114)
\end{aligned}$$

$$\begin{aligned}
&= \frac{1}{2} \ln \beta^\mu - \frac{1}{2} \ln 2\pi - \frac{1}{2} - \ln \Gamma(a^\lambda) + a^\lambda \ln b^\lambda \\
&\quad + \left(a^\lambda - \frac{1}{2} \right) \overline{\ln \lambda} - a^\lambda \quad (2.115)
\end{aligned}$$

2.3 2次元ブラウン運動の動径分布

2次元平面上で、拡散係数 D で自由拡散する粒子の、時刻 t 後の起点からの変位 x は、

$$p(x|D, t) = \frac{x}{2Dt} \exp \left(-\frac{x^2}{4Dt} \right) \quad (2.116)$$

$$= \frac{\delta x}{2} \exp \left(-\frac{\delta x^2}{4} \right) \quad (2.117)$$

にしたがう。ただし、 $\delta \equiv (Dt)^{-1}$ とする。

したがって emission probability は

$$p(x_m|\mathbf{z}_m, \boldsymbol{\delta}) = \left\{ \prod_{i=1}^K \frac{\delta_i x_m}{2} \exp \left(-\frac{\delta_i x_m^2}{4} \right) \right\}^{z_{mi}} \quad (2.118)$$

となる。

状態遷移確率を、遷移確率行列 \mathbf{A} で与えることにすると、 $\mathbf{X}, \mathbf{Z}, \theta$ の同時分布は、

$$\begin{aligned}
p(\mathbf{X}, \mathbf{Z}, \theta) &= p(\theta) \cdot \prod_i^K \pi^{z_{1i}} \cdot \prod_{n=2}^N \prod_i^K \prod_j^K A_{ij}^{z_{n-1,i} z_{nj}} \\
&\quad \times \prod_{m=1}^N \prod_{i=1}^K \left\{ \frac{\delta_i x_m}{2} \exp \left(-\frac{\delta_i x_m^2}{4} \right) \right\}^{z_{mi}} \quad (2.119)
\end{aligned}$$

となる。

2.3.1 E-step :

$$\ln p(x_m | \mathbf{z}_m, \boldsymbol{\delta}) = \sum_{i=1}^K z_{mi} \ln \left\{ \frac{\delta_i x_m}{2} \exp \left(-\frac{\delta_i x_m^2}{4} \right) \right\} \quad (2.120)$$

$$= \sum_{i=1}^K z_{mi} \left\{ \ln \delta_i + \ln x_m - \ln 2 - \frac{\delta_i x_m^2}{4} \right\} \quad (2.121)$$

$$\overline{\ln p(x_m | \mathbf{z}_m, \boldsymbol{\delta})} = \sum_{i=1}^K z_{mi} \left\{ \overline{\ln \delta_i} - \ln x_m - \ln 2 - \frac{1}{4} \overline{\delta_i} x_m^2 \right\} \quad (2.122)$$

式 (1.55) に式 (2.118) を適用し、

$$\tilde{p}(x_m | \mathbf{z}_m, \boldsymbol{\delta}) = \prod_i^K \exp \left(\overline{\ln \delta_i} - \ln x_m - \ln 2 - \frac{1}{4} \overline{\delta_i} x_m^2 \right)^{z_{mi}} \quad (2.123)$$

を得る。

これを、式 (1.53), (1.54) とともに用いて forward-backward アルゴリズムを実行し、 γ, ξ 分布を得る。

2.3.2 M-step :

π, \mathbf{A} に関しては、1.3 節と同様に式 (1.64–1.65, 1.71–1.72) を用いて期待値を求める。

各 i に関しては独立として、 δ に Gamma 事前分布

$$p(\delta_i) = \text{Gam}(\delta_i | u_i^a, u_i^b) \quad (2.124)$$

を与えて (ただし、 u_i^a, u_i^b はハイパーパラメータ)、

$$\begin{aligned} \ln q^*(\delta_i) &= \ln \text{Gam}(\delta_i | u_i^a, u_i^b) \\ &+ \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \cdot \ln \left\{ \frac{\delta_i x_m}{2} \exp \left(-\frac{\delta_i x_m^2}{4} \right) \right\} \right] + \text{const.} \end{aligned} \quad (2.125)$$

δ_i に依存する項だけ取り出すと、

$$\begin{aligned}
&= (u_i^a - 1) \ln \delta_i - u_i^b \delta_i + \mathbb{E}_{\mathbf{Z}} \left[\sum_{m=1}^N z_{mi} \left\{ \ln \delta_i - \frac{\delta_i x_m^2}{4} \right\} \right] \\
&\quad + \text{const.} \tag{2.126}
\end{aligned}$$

$$\begin{aligned}
&= (u_i^a - 1) \ln \delta_i - u_i^b \delta_i + \sum_{m=1}^N \overline{z_{mi}} \left\{ \ln \delta_i - \frac{\delta_i x_m^2}{4} \right\} + \text{const.} \\
&\tag{2.127}
\end{aligned}$$

$$= (u_i^a - 1) \ln \delta_i - u_i^b \delta_i + N_i \ln \delta_i - \frac{R_i}{4} \delta_i + \text{const.} \tag{2.128}$$

ただし、 $N_i = \sum_m^N \overline{z_{mi}}$ 、 $R_i = \sum_m^N \overline{z_{mi}} \cdot x_m^2$ 。

$$= (u_i^a + N_i - 1) \ln \delta_i - \left(u_i^b + \frac{R_i}{4} \right) \delta_i + \text{const.} \tag{2.129}$$

$$= (a_i^\delta - 1) \ln \delta_i - b_i^\delta \delta_i + \text{const.} \tag{2.130}$$

ただし、

$$a_i^\delta = u_i^a + N_i \tag{2.131}$$

$$b_i^\delta = u_i^b + \frac{R_i}{4} \tag{2.132}$$

これら a_i^δ , b_i^δ を使って Gamma 分布 (??) として、

$$q^*(\delta_i) = \text{Gam}(\delta_i | a_i^\delta, b_i^\delta) \tag{2.133}$$

$$= \frac{1}{\Gamma(a_i^\delta)} b_i^{\delta a_i^\delta} \delta_i^{a_i^\delta - 1} e^{-b_i^\delta \delta_i} \tag{2.134}$$

を得る。Gamma 分布の性質と計算により、

$$\overline{\delta_i} = \frac{a_i^\delta}{b_i^\delta} \tag{2.135}$$

$$\overline{\ln \delta_i} = \psi(a_i^\delta) - \ln b_i^\delta \tag{2.136}$$

が得られる。

2.3.3 変分下限 $\mathcal{L}(q)$ の算出

変分下限 $\mathcal{L}(q)$ を計算するため、式 (1.75) から、

$$\begin{aligned}
\mathcal{L}(q) &= \mathbb{E}[\ln p(\boldsymbol{\pi})] + \mathbb{E}[\ln p(\mathbf{A})] + \mathbb{E}[\ln p(\boldsymbol{\mu}, \boldsymbol{\lambda})] \\
&\quad - \mathbb{E}[\ln q(\boldsymbol{\pi})] - \mathbb{E}[\ln q(\mathbf{A})] - \mathbb{E}[\ln q(\boldsymbol{\mu}, \boldsymbol{\lambda})] + \prod_n^N \tilde{c}_n \tag{2.137}
\end{aligned}$$

を得る。

$\mathbb{E}[\ln p(\boldsymbol{\pi})]$, $\mathbb{E}[\ln p(\mathbf{A})]$, $\mathbb{E}[\ln q(\boldsymbol{\pi})]$, $\mathbb{E}[\ln q(\mathbf{A})]$ に関しては、式 (1.79), (1.83), (1.86), (1.90) で、 \tilde{c}_n に関しては E-step で、それぞれ得られているので、以下ではそれ以外の項について計算する。

$\mathbb{E}[\ln p(\boldsymbol{\delta})]$:

$$\mathbb{E}[\ln p(\boldsymbol{\delta})] = \mathbb{E}\left[\ln \prod_i^K \text{Gam}(\delta_i | u_i^a, u_i^b)\right] \quad (2.138)$$

$$= \mathbb{E}\left[\ln \prod_i^K \left\{ \frac{1}{\Gamma(u_i^a)} u_i^{b u_i^a} \delta_i^{u_i^a - 1} e^{-u_i^b \delta_i} \right\}\right] \quad (2.139)$$

$$= \mathbb{E}\left[\sum_i^K \left\{ -\ln \Gamma(u_i^a) + u_i^a \ln u_i^b + (u_i^a - 1) \ln \delta_i - u_i^b \delta_i \right\}\right] \quad (2.140)$$

$$= \sum_i^K \left\{ -\ln \Gamma(u_i^a) + u_i^a \ln u_i^b + (u_i^a - 1) \overline{\ln \delta_i} - u_i^b \overline{\delta_i} \right\} \quad (2.141)$$

$\mathbb{E}[\ln q(\boldsymbol{\delta})]$:

$$\mathbb{E}[\ln q(\boldsymbol{\delta})] = \mathbb{E}\left[\ln \prod_i^K \text{Gam}(\delta_i | a_i^\delta, b_i^\delta)\right] \quad (2.142)$$

$$= \mathbb{E}\left[\ln \prod_i^K \frac{1}{\Gamma(a_i^\delta)} b_i^{\delta a_i^\delta} \delta_i^{a_i^\delta - 1} e^{-b_i^\delta \delta_i}\right] \quad (2.143)$$

$$= \mathbb{E}\left[\sum_i^K \left\{ -\ln \Gamma(a_i^\delta) + a_i^\delta \ln b_i^\delta + (a_i^\delta - 1) \ln \delta_i - b_i^\delta \delta_i \right\}\right] \quad (2.144)$$

$$= \sum_i^K \left\{ -\ln \Gamma(a_i^\delta) + a_i^\delta \ln b_i^\delta + (a_i^\delta - 1) \overline{\ln \delta_i} - b_i^\delta \overline{\delta_i} \right\} \quad (2.145)$$

$$= \sum_i^K \left\{ -\ln \Gamma(a_i^\delta) + a_i^\delta \ln b_i^\delta + (a_i^\delta - 1) \overline{\ln \delta_i} - a_i^\delta \right\} \quad (2.146)$$